

# AiSD

Rafał Włodarczyk

INA 4, 2025

## Contents

<b>1</b>	<b>Lecture I - Sortowanie</b>	<b>4</b>
1.1	Worst-case analysis . . . . .	4
1.2	Average-case analysis . . . . .	4
1.3	Analiza losowego sortowania . . . . .	4
1.4	Insertion Sort $(A, n)$ . . . . .	4
1.4.1	Worst-case analysis - Insertion Sort $(A, n)$ . . . . .	5
1.4.2	Average-case analysis - Insertion Sort $(A, n)$ . . . . .	5
1.5	Przykład złożoności . . . . .	5
<b>2</b>	<b>Lecture II - Merge Sort</b>	<b>6</b>
2.1	Merge sort $(A, 1, n)$ . . . . .	6
<b>3</b>	<b>Lecture III - Narzędzia do analizy algorytmów</b>	<b>8</b>
3.1	Notacja asymptotyczna . . . . .	8
3.2	Notacja Big- $O$ . . . . .	8
3.3	Notacja Big- $\Omega$ . . . . .	9
3.4	Notacja Big- $\Theta$ . . . . .	10
3.5	Notacja small- $o$ . . . . .	10
3.6	Notacja small- $\omega$ . . . . .	10
3.7	Metody rozwiązywania rekurencji . . . . .	11
3.8	Rozwiązywanie rekurencji . . . . .	11
3.9	Metoda podstawiania - Metoda dowodu indukcyjnego . . . . .	11
<b>4</b>	<b>Lecture IV - Metoda drzewa rekursji</b>	<b>12</b>
4.1	Metoda drzewa rekursji . . . . .	12
4.2	Metoda iteracyjna . . . . .	14
4.3	Master Theorem . . . . .	15
4.4	Divide and Conquer . . . . .	17
4.5	Wyszukiwanie elementów w portowanej tablicy . . . . .	17
4.6	Binary search . . . . .	17

<b>5</b>	<b>Lecture V - Divide and Conquer</b>	<b>17</b>
5.1	Potęgowanie liczby . . . . .	17
5.2	Wyliczenie $n$ -tej liczby Fibonacciego . . . . .	18
5.3	Mnożenie Liczb . . . . .	18
5.4	Mnożenie macierzy . . . . .	20
5.5	Quick Sort . . . . .	20
<b>6</b>	<b>Lecture VI - Quicksort</b>	<b>21</b>
6.1	Lomuto Partition . . . . .	21
6.2	Hoare Partition . . . . .	22
6.3	Worst Case Analysis for QS . . . . .	23
6.4	Best case Analysis for QS . . . . .	24
6.5	Specific case analysis for QS . . . . .	24
6.6	Best/Worst case analysis for QS - Intuition . . . . .	25
6.7	Average case analysis for QS . . . . .	25
<b>7</b>	<b>Lecture VII - Quicksort - further analysis</b>	<b>27</b>
7.1	Strategia Count . . . . .	28
7.2	Counting Sort . . . . .	28
7.3	Radix Sort . . . . .	29
<b>8</b>	<b>Lecture VIII</b>	<b>29</b>
8.1	Poprawność Radix Sort . . . . .	29
8.2	Złożoność obliczeniowa Radix Sort . . . . .	29
8.3	Statystyki pozycyjne . . . . .	30
8.4	RandomSelect(A,p,q,i) . . . . .	30
8.5	Best Case dla RandomSelect . . . . .	31
8.6	Worst Case dla RandomSelect . . . . .	31
8.7	Average Case dla RandomSelect . . . . .	31
8.8	Select(A,p,q,i) . . . . .	32
<b>9</b>	<b>Lecture IX - Select</b>	<b>33</b>
9.1	Struktury Danych . . . . .	35
9.2	Binary Search Tree . . . . .	35
9.3	Operacje na BST . . . . .	36
<b>10</b>	<b>Lecture X</b>	<b>37</b>
10.1	Wysokość Drzewa BST . . . . .	37
10.2	BST_Sort . . . . .	38
<b>11</b>	<b>Lecture XI</b>	<b>41</b>
11.1	Red Black Trees . . . . .	41
11.2	Red Black Tree Example . . . . .	41
11.3	Insert w Red Black Trees . . . . .	42
<b>12</b>	<b>Lecture XI</b>	<b>44</b>
12.1	Wzbogacanie struktur danych . . . . .	44

<b>13 Lecture XII</b>	<b>44</b>
13.1 Funkcje Hashujące . . . . .	44
<b>14 Lecture XIII</b>	<b>45</b>
14.1 Programowanie Dynamiczne - Wstęp . . . . .	45
14.2 Przykład programowania dynamicznego - Ciąg Fibonacciego . . . . .	46
14.3 Najdłuższy rosnący podciąg . . . . .	46
14.4 Problem wyznaczania reszty . . . . .	46
14.5 Rozkład liczby pierwszej . . . . .	47
14.6 Knapsack - Problem Plecakowy . . . . .	48
14.7 Optymalne Mnożenie Macierzy . . . . .	49
<b>15 Lecture XIV</b>	<b>49</b>
15.1 Programowanie Dynamiczne - Kontynuacja . . . . .	49
15.2 Grafy Skierowane . . . . .	49
15.3 Najkrótsze ścieżki w DAG'ach - Directed Acyclic Graph . . . . .	49
15.4 Edit Distance Problem . . . . .	50
<b>16 Lecture XV</b>	<b>51</b>
16.1 Kopiec binarny (Binary Heap) . . . . .	51
16.2 Własność kopca (maksymalnego) . . . . .	51
16.3 Kolejka Priorytetowa (PQ) . . . . .	55

*I welcome you on the path to insanity.*

*Good luck :)*

# 1 Lecture I - Sortowanie

Definiujemy problem:

1. Input:  $A = (a_1, \dots, a_n)$ ,  $|A| = n$
2. Output: Permutacja tablicy wyjściowej  $(a'_1, a'_2, \dots, a'_n)$ , takie że:  $a'_1 \leq a'_2 \leq \dots \leq a'_n$ .

## 1.1 Worst-case analysis

$$T(n) = \max_{\text{wszystkie wejścia}} \{\text{\#operacji po wszystkich } |n|\text{-wejściach}\} \quad (1.1.1)$$

## 1.2 Average-case analysis

Zakładamy pewien rozkład prawdopodobieństwa na danych wyjściowych. Z reguły myślimy o rozkładzie jednostajnym. Niech  $T$  - zmienna losowa liczby operacji wykonanych przez badany algorytm.

$$\mathbf{E}(T) - \text{wartość oczekiwana } T \quad (1.2.1)$$

Później możemy badać wariancję, oraz koncentrację.

## 1.3 Analiza losowego sortowania

Dla poprzedniego algorytmu zobaczmy, że:  $n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n$  [czyli  $f(n) \sim g(n) \equiv \lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = 1$ ].  
To jest tragiczna złożoność.

## 1.4 Insertion Sort $(A, n)$

$(A, n) = ((a_1, a_2, \dots, a_n), n)$

```
for j = 2...n
{
    key = A[j]
    i=j-1
    while(i>0 && A[i]>key) {
        A[i+1] = A[i]
        i = i - 1
    }
    A[i+1] = key
}
```

Przykład:  $A = (8, 2, 4, 9, 3, 6), n = 6$

- $8_i, 2_j, 4, 9, 3, 6$   $j = 2, i = 1, key = 2$  while
- $2, 8_j, 4, 9, 3, 6$
- $2, 8_i, 4_j, 9, 3, 6$   $j = 3, i = 2, key = 4$  while

- 2, 4, 8, 9, 3, 6
- 2, 4, 8<sub>i</sub>, 9<sub>j</sub>, 3, 6     $j = 4, i = 3, key = 9$  no while
- 2, 4, 8, 9<sub>i</sub>, 3<sub>j</sub>, 6     $j = 5, i = 4, key = 3$  while
- 2, 3, 4, 8, 9, 6
- 2, 3, 4, 8, 9<sub>i</sub>, 6<sub>j</sub>     $j = 6, i = 5, key = 6$  while
- 2, 3, 4, 6, 8, 9

```
| <= x | > x | x | ... |
| <= x | x | > x | ... |
```

Porównujemy element ze wszystkim co jest przed nim - wszystko przed  $j$ -tym elementem będzie posortowane. Insertion sort nie swapuje par elementów w tablicy, a przenosi tam gdzie jest jego miejsce.

#### 1.4.1 Worst-case analysis - Insertion Sort ( $A, n$ )

Odwrotnie posortowana tablica powoduje najwięcej przesunięć. Ponieważ ustaliliśmy że liczba operacji w while zależy od  $j$ , wtedy:

$$T(n) = \sum_{j=2}^n O(j-1) = \sum_{j=1}^{n-1} O(j) = O\left(\sum_{j=1}^{n-1} j\right) = \quad (1.4.1)$$

$$= O\left(\frac{1+n-1}{2} \cdot (n-1)\right) = O\left(\frac{(n-1) \cdot (n)}{2}\right) = O\left(\frac{n^2}{2}\right) = O(n^2) \quad (1.4.2)$$

#### 1.4.2 Average-case analysis - Insertion Sort ( $A, n$ )

Policzmy dla uproszczenia, że na wejściu mamy  $n$ -elementowe permutacje, z których każda jest jednakowo prawdopodobna  $p = \frac{1}{n!}$ . Spróbujmy wyznaczyć  $\mathbf{E}$ , korzystając z inwersji permutacji. Wartość oczekiwana liczby inwersji w losowej permutacji wynosi:

$$\mathbf{E} \sim \frac{n^2}{4} \quad (1.4.3)$$

Pominęliśmy stałe wynikające z innych operacji niż porównywanie. W average-case będziemy około połowę szybciej niż w worst-case.

*Pseudokod bez przykładu jest słaby.*

### 1.5 Przykład złożoności

Patrzemy na wiodący czynnik.

$$13n^2 + 91n \log n + 4n + 13^{10} = O(n^2) \quad (1.5.1)$$

$$= 13n^2 + O(n \log n) \quad (1.5.2)$$

Chcielibyśmy gdzie to konieczne, zapisać *lower order terms*.

*Pytanie o dzielenie liczb* - istnieją algorytmy, które ze względu na arytmetyczne właściwości liczb sprawiają, że mniejsze liczby mogą dzielić się dłużej niż większe. Podczas tego kursu nie omawiamy złożoności dla takich algorytmów.

## 2 Lecture II - Merge Sort

### 2.1 Merge sort ( $A, 1, n$ )

Niech złożoność  $T(n)$  - złożoność algorytmu.

Funkcja Merge Sort stanowi o strukturze algorytmu:

```
MERGE_SORT(A,1,n)
if |A[1...n]| == 1 return A[1...n]          | 0(1)
else
    B = MERGE_SORT(A,1,floor(n/2))          | T(floor(n/2))
    C = MERGE_SORT(A,floor(n/2)+1, n)       | T(ceil(n/2))
    return MERGE(B,C)                       | 0(n)
```

Funkcja Merge pozwala łączyć poszczególne wywołania rekurencyjne:

```
MERGE(X[1...k], Y[1...l])
if k = 0 return Y[1...l]
if l = 0 return X[1...k]
if X[1] <= Y[1]
    return X[1] o MERGE(X[2...k], Y[1...l])
else
    return Y[1] o MERGE(X[1...k], Y[2...l])
```

```
MERGE(A,B)
2 1 ---> [1] + MERGE(A,B (bez 1))
7 9
13 10
19 11
20 14

2 9 ---> [1,2] + MERGE(A (bez 2),B)
7 10
13 11
19 14
20 .

... ---> [1,2,7,9,10,11,13,14]
19 .
20 .

... ---> [1,2,7,9,10,11,13,14,19,20]
```

[10], [2], [5], [3], [7], [13], [1], [6]

[2, 10], [3, 5], [7, 13], [1, 6]

[2, 3, 5, 10], [1, 6, 7, 13]


[1, 2, 3, 5, 6, 7, 10, 13]

Złożoność obliczeniowa merge-a wynosi  $O(k + l)$  - w najgorszym przypadku bierzemy najpierw z jednej strony, potem z drugiej i na zmianę.

$$T(n) = T\left(\left\lfloor \frac{n}{2} \right\rfloor\right) + T\left(\left\lceil \frac{n}{2} \right\rceil\right) + O(n) \quad (2.1.1)$$

$$T(n) = 2 \cdot T\left(\frac{n}{2}\right) + O(n) \quad (2.1.2)$$

Rozpiszmy tzw drzewo rekursji:



Musimy dodać wszystkie koszty, które pojawiły się w drzewie. Dodajmy piętra, a następnie zsumujmy. Żeby znać wysokość drzewa interesuje nas dla jakiego  $h$  znajdzie  $\frac{n}{2^h} = 1$

$$\frac{n}{2^h} = 1 \implies 2^h = n \implies h = \log_2 n \quad (2.1.3)$$

Zatem złożoność:

$$\sum_{i=1}^{\log n} cn = cn \log n \sim O(n \log n) \quad (2.1.4)$$

### 3 Lecture III - Narzędzia do analizy algorytmów

*Dzisiejszy wykład prowadzi GODfryd*

#### 3.1 Notacja asymptotyczna

- Big- $O$  ( $O$ -duże)  $f : \mathbb{N} \rightarrow \mathbb{R}$
- Big- $\Omega$  ( $\Omega$ -duże)  $f : \mathbb{N} \rightarrow \mathbb{R}$
- Big- $\Theta$  ( $\Theta$ -duże)  $f : \mathbb{N} \rightarrow \mathbb{R}$
- Small- $o$  ( $o$ -małe)  $f : \mathbb{N} \rightarrow \mathbb{R}$

#### 3.2 Notacja Big- $O$

**Definition. Notacja Big- $O$ .** Funkcja  $f(n) \in O(g(n))$ , gdy:

$$f(n) = O(g(n)) \equiv (\exists c > 0) (\exists n_0 \in \mathbb{N}) (\forall n \geq n_0) (|f(n)| \leq c \cdot |g(n)|)$$

Przykład:  $2n^2 = O(n^3)$ , dla  $n_0 = 2, c = 1$  definicja jest spełniona.

*Pomijamy tutaj stałe - interesuje nas rząd wielkości*

$$O(g(n)) = \{f \in \mathbb{N}^{\mathbb{R}} : f \text{ spełnia definicję}\}$$

$O(g(n))$  jest klasą funkcji, ale jako informatycy możemy zapisywać  $f = O(g)$ , zamiast  $f \in O(g)$ . Notacja nie ma symetrii, to znaczy  $f = O(g) \nrightarrow g = O(f)$



**Fact. Definicja Big-O za pomocą granicy.** Możemy zapisać alternatywnie:

$$f(n) = O(g(n)) \equiv \limsup_{n \rightarrow \infty} \left| \frac{f(n)}{g(n)} \right| \leq \infty$$

Uwaga. Jeśli  $\lim_{n \rightarrow \infty} \left| \frac{f(n)}{g(n)} \right| < \infty$  (istnieje), to:

$$\limsup_{n \rightarrow \infty} \left| \frac{f(n)}{g(n)} \right| = \lim_{n \rightarrow \infty} \left| \frac{f(n)}{g(n)} \right|$$

Przykłady:

$$\begin{cases} f(n) = n^2 \\ g(n) = (-1)^n n^2 \end{cases} \quad (3.2.1)$$

Granica nie istnieje, ale  $\limsup = 1$

$$\frac{f(n)}{g(n)} = \begin{cases} 1, & 2 \mid n \\ \frac{1}{n}, & 2 \nmid n \end{cases} \quad (3.2.2)$$

Granica nie istnieje.

**Fact. Dokładność zapisu Big-O.** Pomijamy składniki niższego rzędu jako mniej istotne, ale podkreślamy że istnieją:

$$f(n) = n^3 + O(n^2) \equiv (\exists h(n) = O(n^2)) (f(n) = n^3 + h(n)) \quad (3.2.3)$$

Rozważmy następnie stwierdzenie:

$$n^2 + O(n) = O(n^2) \equiv (\forall f(n) = O(n)) (\exists h(n) = O(n^2)) (n^2 + f(n) = h(n)) \quad (3.2.4)$$

Rozumiemy to następująco - dodając dowolną funkcję z klasy funkcji liniowych do  $n^2$  otrzymamy funkcję z klasy funkcji kwadratowych.

### 3.3 Notacja Big-Ω

**Definition. Notacja Big-Ω.** Funkcja  $f(n) \in \Omega(g(n))$ , gdy:

$$f(n) = \Omega(g(n)) \equiv (\exists c > 0) (\exists n_0 \in \mathbb{N}) (\forall n \geq n_0) (|f(n)| \geq c \cdot |g(n)|) \quad (3.3.1)$$

biorąc  $c' = \frac{1}{c} > 0$  mamy:  $(|g(n)| \leq c' \cdot |f(n)|)$ , czyli  $g(n) = O(f(n))$ .

Przykład:

$$2n^2 = O(n^3) \quad (3.3.2)$$

$$n^3 = \Omega(2n^2) \quad (3.3.3)$$

$$n = \Omega(\log n) \quad (3.3.4)$$

*Każda funkcja jest Omega od siebie samej.*

### 3.4 Notacja Big- $\Theta$

**Definition. Notacja Big- $\Theta$ .** Funkcja  $f(n) \in \Theta(g(n))$ , gdy:

$$f(n) = \Theta(g(n)) \equiv (\exists c_1, c_2 > 0) (\exists n_0 \in \mathbb{N}) (\forall n \geq n_0) (c_1 \cdot |g(n)| \leq |f(n)| \leq c_2 \cdot |g(n)|) \quad (3.4.1)$$

Przykład:

$$n^2 = \Theta(2n^2) \quad (3.4.2)$$

$$n^3 = \Theta(n^3) \quad (3.4.3)$$

$$n^4 + 3n^2 + \log n = \Theta(n^4) \quad (3.4.4)$$

**Fact. Dokładność zapisu Theta.**

$$f(n) = \Theta(g(n)) \equiv f(n) = O(g(n)) \wedge f(n) = \Omega(g(n)) \quad (3.4.5)$$

$$\Theta(f(n)) = O(f(n)) \cap \Omega(f(n)) \quad (3.4.6)$$

Rozważmy przypadek patologiczny

$$f(n) = n^{1+\sin \frac{\pi \cdot n}{2}} \quad g(n) = n \quad (3.4.7)$$

$$f \neq O(g), g \neq O(f) \quad (3.4.8)$$

### 3.5 Notacja small- $o$

**Definition. Notacja small- $o$ .** Funkcja  $f(n) \in o(g(n))$ , gdy:

$$f(n) = o(g(n)) \equiv (\forall c > 0) (\exists n_0 \in \mathbb{N}) (\forall n \geq n_0) (|f(n)| < c \cdot |g(n)|) \quad (3.5.1)$$

Równoważnie:

$$f(n) = o(g(n)) \equiv \lim_{n \rightarrow \infty} \left| \frac{f(n)}{g(n)} \right| = 0 \quad (3.5.2)$$

Przykład:

$$n = o(n^2) \quad (3.5.3)$$

$$n^2 = o(n^3) \quad (3.5.4)$$

$$n^3 = o(2^n) \quad (3.5.5)$$

### 3.6 Notacja small- $\omega$

**Definition. Notacja small- $\omega$ .** Funkcja  $f(n) \in \omega(g(n))$ , gdy:

$$f(n) = \omega(g(n)) \equiv (\forall c > 0) (\exists n_0 \in \mathbb{N}) (\forall n \geq n_0) (|f(n)| > c \cdot |g(n)|) \quad (3.6.1)$$

Równoważnie:

$$f(n) = \omega(g(n)) \equiv \lim_{n \rightarrow \infty} \left| \frac{f(n)}{g(n)} \right| = \infty \quad (3.6.2)$$

Przykład:

$$3.14n^2 + n = O(n^3) = \omega(n) \quad (3.6.3)$$

### 3.7 Metody rozwiązywania rekurencji

- Metoda podstawienia (indukcji) - Cormen
- Metoda drzewa rekursji
- Metoda master theorem

### 3.8 Rozwiązywanie rekurencji

1. Zgadnij odpowiedź (wiodący składnik)
2. Sprawdź przez indukcję, czy dobrze zgadliśmy
3. Wylicz stałe

**Information. Historyjka.** Dwóch przyjaciół zgubiło się podczas podróży balonem.

- "Gdzie jesteśmy?"
- "W balonie."

Osoba, którą spotkali, była matematykiem.

Odpowiedź była precyzyjna, dokładna i całkowicie bezużyteczna.

### 3.9 Metoda podstawiania - Metoda dowodu indukcyjnego

Przykład 1. Rozwiążmy równanie rekurencyjne:

$$T(n) = 4T\left(\frac{n}{2}\right) + n \quad T(1) = \Theta(1) \quad (3.9.1)$$

Założmy, że  $T(n) = O(n^3)$  - pokazać, że  $T(n) \leq c \cdot n^3$  dla dużych  $n$ .

1. Krok początkowy  $T(1) = \Theta(1) \leq c \cdot 1^3 = c$  ok.
2. Założmy, że  $\forall_{k < n} T(k) \leq c \cdot k^3$  (zał. indukcyjne, nie  $\Theta(k^3)$  - chcemy konkretną stałą  $c$ )
3.  $T(n) = 4T\left(\frac{n}{2}\right) + n \leq 4c\left(\frac{n}{2}\right)^3 + n = \frac{1}{2}cn^3 + n = cn^3 - \frac{1}{2}cn^3 + n \leq cn^3$ .
4. Wystarczy wskazać  $c$ , takie że  $\frac{1}{2}cn^3 - n \geq 0$ , np  $c \geq 2$
5. Pokazaliśmy, że  $T(n) = O(n^3)$

Założmy, że  $T(n) = O(n^2)$  - pokazać, że  $T(n) \leq c \cdot n^2$  dla dużych  $n$ .

1. Krok początkowy  $T(1) = \Theta(1) \leq c \cdot 1^2 = c$  ok.
2. Założmy, że  $\forall_{k < n} T(k) \leq c \cdot k^2$  (zał. indukcyjne)
3.  $T(n) = 4T\left(\frac{n}{2}\right) + n \leq 4c\left(\frac{n}{2}\right)^2 + n = cn^2 + n = cn^2 - cn^2 + n \leq cn^2$ .
4. Tego się nie da pokazać - nie jest prawdą, że  $T(n) = O(n^2)$

Wzmocnijmy zatem założenie indukcyjne:

1.  $T(n) \leq c_1 n^2 - c_2 n$  (zał. indukcyjne)
2.  $T(n) = 4T\left(\frac{n}{2}\right) + n \leq 4\left(c_1 \frac{n^2}{2} - c_2 \frac{n}{2}\right) + n$
3.  $= c_1 n^2 - 2c_2 n + n = c_1 n^2 - (2c_2 - 1)n \leq$
4.  $\leq c_1 n^2 - c_2 n$
5. Weźmy  $c_1 = 1, c_2 = 2$ , wtedy  $T(n) \leq n^2 - 2n = O(n^2)$

Przykład 2. Weźmy paskudną rekursję  $T(n) = 2T(\sqrt{n}) + \log n$ .  
Założmy, że  $n$  jest potęgą 2 oraz oznaczmy  $n = 2^m, m = \log_2 n$ .

$$T(2^m) = 2T((2^m)^{\frac{1}{2}}) + m \quad (3.9.2)$$

Oznaczmy  $T(2^m) = S(m)$ . Wtedy:

$$S(m) = 2S\left(\frac{m}{2}\right) + m \quad (3.9.3)$$

(dobrze znana rekurencja -  $S(n) = O(m \log m)$ ) - patrz Lecture 2. Przejdźmy z powrotem na  $T, n$ :

$$T(2^m) = S(m) \quad (3.9.4)$$

$$T(2^m) = O(m \log m) \quad (3.9.5)$$

$$T(n) = O(\log n \log \log n) \quad (3.9.6)$$

Formalnie pokazaliśmy to tylko dla potęg 2 - musielibyśmy jeszcze indukcyjnie to udowodnić.

*Kiedy podłogi i sufity mają znaczenie?*

## 4 Lecture IV - Metoda drzewa rekursji

### 4.1 Metoda drzewa rekursji

W danym węźle wstawiamy koszt operacji. Sumujemy koszty węzłów na danym poziomie.

$$T(n) = T\left(\frac{n}{2}\right) + T\left(\frac{n}{4}\right) + n^2, \quad T(1) = \Theta(1) \quad (4.1.1)$$

Chcemy sumować koszty na danym poziomie, a potem napisać pełną sumę.

$$\begin{array}{rcl}
 & n^2 & | \quad n^2 \\
 & / \quad \backslash & \\
 (n/2)^2 & & (n/4)^2 \quad | \quad 5/16 \quad n^2 \\
 / \quad \backslash & & / \quad \backslash \\
 (n/4)^2 \quad (n/8)^2 & (n/8)^2 \quad (n/16)^2 & | \quad 25/256 \quad n^2 = (5/16)^k \quad n^2 \\
 \dots & &
 \end{array}$$

$$T^*(n) = \sum_{k=0}^{\infty} \left(\frac{5}{16}\right)^k n^2 = \quad (4.1.2)$$

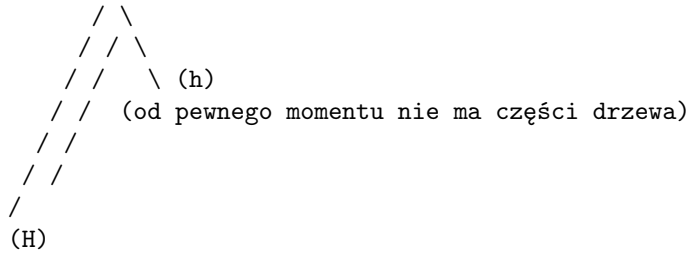
$$= n^2 \sum_{k=0}^{\infty} \left(\frac{5}{16}\right)^k = \quad (4.1.3)$$

$$= n^2 \cdot \left(\frac{1}{1 - \frac{5}{16}}\right) = \quad (4.1.4)$$

$$= \frac{16}{11} n^2 \quad (4.1.5)$$

Nie mogłoby być mniej niż  $n^2$ , bo już w pierwszym rzędzie jest  $n^2$ .  
Nie jest to dokładne, ale dostaliśmy górne ograniczenie.

$$T(n) = O(n^2) \quad (4.1.6)$$



Wysokości różnią się o stałą:

$$\frac{n}{2^H} = 1 \implies H = \log_2 n \quad (4.1.7)$$

$$\frac{n}{4^h} = 1 \implies h = \log_4 n \quad (4.1.8)$$

*Za chwilę będę dodawał rzeczy, które nie istnieją*

Pamiętajmy, że:

$$a^{\log_b n} = n^{\log_b a}$$

$$\hat{T}(n) = \sum_{k=0}^{H=\log_2(n)} \left(\frac{5}{16}\right)^k n^2 = \quad (4.1.9)$$

$$= n^2 \sum_{k=0}^H \left(\frac{5}{16}\right)^k = \quad (4.1.10)$$

$$= n^2 \cdot \frac{1}{11} \left( 16 - 5 \left(\frac{5}{16}\right)^{\log_2 n} \right) = \quad (4.1.11)$$

$$= \frac{16}{11} n^2 - \frac{5}{11} n^{2-1.67} \quad (4.1.12)$$

Rozważmy ograniczenie dolne:

$$\check{T}(n) = \sum_{k=0}^{h=\log_4(n)} \left(\frac{5}{16}\right)^k n^2 = n^2 \frac{1}{11} \left( 16 - C \cdot \left(\frac{5}{16}\right)^{\log_4 n} \right) \quad (4.1.13)$$

Zatem wiemy, że:

$$T(n) = O(\hat{T}(n)) = O(T^*(n)) \quad (4.1.14)$$

$$T(n) = \Omega(\check{T}(n)) \quad (4.1.15)$$

$$T(n) = \Theta(n^2) = \frac{16}{11} n^2 + o(n^2) \quad (4.1.16)$$

## 4.2 Metoda iteracyjna

$$T(n) = 3T\left(\frac{n}{4}\right) + n = \quad (4.2.1)$$

$$T(n) = 3 \left( 3T\left(\frac{n}{16}\right) + \frac{n}{4} \right) + n = 9T\left(\frac{n}{16}\right) + \frac{3}{4}n + n = \quad (4.2.2)$$

$$T(n) = n + \frac{3}{4}n + 9 \left( 3T\left(\frac{n}{64}\right) + \frac{n}{16} \right) = \quad (4.2.3)$$

$$T(n) = n + \frac{3}{4}n + \frac{9}{16}n + 27T\left(\frac{n}{64}\right) = \quad (4.2.4)$$

$$T(n) = n + \frac{3}{4}n + \left(\frac{3}{4}\right)^2 n + \left(\frac{3}{4}\right)^3 n + \dots + 3^j T\left(\frac{n}{4^j}\right) = \quad (4.2.5)$$

$$(4.2.6)$$

Wyznaczmy koniec iteracji:

$$\frac{n}{4^j} = 1 \implies j = \log_4 n \quad (4.2.7)$$

To jest nic innego jak:

$$\sum_{j=0}^{\log_4 n} \left(\frac{3}{4}\right)^j = O(n) \quad (4.2.8)$$

### 4.3 Master Theorem

**Theorem. Master Theorem.** Jeśli  $T(n) = a \cdot T(\lceil \frac{n}{b} \rceil) + \Theta(n^d)$  dla pewnych stałych  $a > 0, b > 1, d > 0$ , oraz  $T(1) = \Theta(1)$  to:

$$T(n) = \begin{cases} \Theta(n^d) & \text{jeśli } d > \log_b a \\ \Theta(n^d \log n) & \text{jeśli } d = \log_b a \\ \Theta(n^{\log_b a}) & \text{jeśli } d < \log_b a \end{cases}$$

$$\hat{T}(n) = a \cdot \hat{T}\left(\frac{n}{b} + 1\right) + \Theta(n^d) \quad (4.3.1)$$

$$\check{T}(n) = a \cdot \check{T}\left(\frac{n}{b}\right) \quad (4.3.2)$$

Dowód

wielkość	.	liczba podproblemów
$n$	$c \cdot n^d$	1
$n/b$	$c \cdot (n/b)^d$	$a$
$n/b^2$	$c \cdot (n/(b^2))^d$	$a^2$

...

koszt na poziomie ' $k$ ' =  $c \cdot (n/b^k)^d$

liczba podproblemów na poziomie ' $k$ ' =  $a^k$

suma kosztów ' $k$ '-tym wierszu =  $c \cdot (a/b^d)^k \cdot n^d$

Wysokość drzewa rekursji

$$\frac{n}{b^h} = 1 \implies h = \log_b n \quad (4.3.3)$$

Zatem:

$$T(n) = \Theta\left(\sum_{k=0}^{\log_b n} \left(\frac{a}{b^d}\right)^k n^d\right) \quad (4.3.4)$$

Mogę wziąć  $\theta$  zamiast  $o$ , bo dość dokładnie robię - ale trochę nie

$$\sum_{k=0}^h q^k = \frac{1 - q^{h+1}}{1 - q} \quad \sum_{h=0}^h 1^k = (h+1)$$

$$T(n) = \Theta\left(n^d \sum_{k=0}^{\log_b n} \left(\frac{a}{b^d}\right)^k\right) \quad (4.3.5)$$

(1) Jeśli  $\frac{a}{b^d} < 1$ , to:

$$a < b^d \quad (4.3.6)$$

$$\log_b(a) < d \quad \text{zatem} \quad (4.3.7)$$

$$T(n) = \Theta(n^d) \quad (4.3.8)$$

(większość pracy dzieje się z korzenia - okolic korzenia)

(2) Jeśli  $\frac{a}{b^d} = 1$ , to:

$$a = b^d \quad (4.3.9)$$

$$\log_b(a) = d \quad (4.3.10)$$

$$T(n) = \Theta(n^d \log n) \quad (4.3.11)$$

(suma kosztów w  $k$ -tym wierszu - każdy wiersz kontrybuuje równie mocno)

(3) Jeśli  $\frac{a}{b^d} > 1$ , to:

$$a > b^d \quad (4.3.12)$$

$$\log_b(a) > d \quad (4.3.13)$$

$$T(n) = \Theta(n^{\log_b a}) \quad (4.3.14)$$

(z każdym kolejnym poziomem koszt rośnie - większość złożoności kryje się na dole drzewa rekursji)

*Z tego co dzieje się na początku... albo na końcu, bo to może być scalanie Stworzyliście za dużo podproblemów.*

Co jeśli rekurencja nie ma  $n^d$ , a ma  $n \log(n)$ ? - możemy przybliżyć

Przykład

$$T(n) = 4T\left(\frac{n}{2}\right) + 11n \quad a = 4, b = 2, d = 1 \quad (4.3.15)$$

$$\log_b a = \log_2 4 = 2 > 1 = d \quad \text{to jest przypadek (3)} \quad (4.3.16)$$

$$T(n) = \Theta(n^{\log_a b}) = \Theta(n^{\log_2 4}) = \Theta(n^2) \quad (4.3.17)$$

Przykład

$$T(n) = 4T\left(\frac{n}{3}\right) + 3n^2 \quad a = 4, b = 3, d = 2 \quad (4.3.18)$$

$$\log_b a = \log_3 4 < 2 = d \quad \text{to jest przypadek (1)} \quad (4.3.19)$$

$$T(n) = \Theta(n^d) = \Theta(n^2) \quad (4.3.20)$$



Przykład

$$T(n) = 27T\left(\frac{n}{3}\right) + 0.(3)n^3 \quad a = 27, b = 3, d = 3 \quad (4.3.21)$$

$$\log_b a = \log_3 27 = 3 = d \quad \text{to jest przypadek (2)} \quad (4.3.22)$$

$$T(n) = \Theta(n^d \log n) = \Theta(n^3 \log n) \quad (4.3.23)$$

#### 4.4 Divide and Conquer

1. Podział problemu na mniejsze podproblemy.
2. Rozwiąż rekurencyjnie mniejsze (rozłączne) podproblemy.
3. Połącz rozwiązania problemów w celu rozwiązania problemu wejściowego.

#### 4.5 Wyszukiwanie elementów w portowanej tablicy

- Input - posortowana tablica  $A[1..n]$ , element  $x$
- Output - indeks  $i$  taki, że  $A[i] = x$  lub błąd, gdy  $x$  nie występuje w  $A$

#### 4.6 Binary search

1. if  $n = 1, A[n] = x$  return  $n$ , else  $A$  does not contain  $x$
2. porównujemy  $x$  z  $A[\frac{n}{2}]$
3. jeśli  $x = A[\frac{n}{2}]$  return  $\frac{n}{2}$
4. jeśli  $x < A[\frac{n}{2}]$ , BinarySearch( $A[1..\frac{n}{2} - 1], x$ )
5. jeśli  $x > A[\frac{n}{2}]$ , BinarySearch( $A[\frac{n}{2} + 1..n], x$ )

*Wy nie patrzcie na pseudokody na tablicy, tylko w książce*

$$T(n) = 1 \cdot T\left(\frac{n}{2}\right) + \Theta(1) \quad (4.6.1)$$

$$T(n) = \Theta(\log n) \quad (4.6.2)$$

## 5 Lecture V - Divide and Conquer

### 5.1 Potęgowanie liczby

- Input - liczba  $x$ , liczba całkowita  $n$

- Output -  $x^n$

Bazowo zachodzi  $n - 1$  mnożeń  $x$  przez siebie. (czyli  $\Theta(n)$  operacji)

$$x \cdot x \cdot \dots \cdot x = x^n \quad (5.1.1)$$

Zróbmy to sprytniej:

$$x^n = \begin{cases} x^{\frac{n}{2}} \cdot x^{\frac{n}{2}} & \text{dla parzystego } n \\ x^{\frac{n-1}{2}} \cdot x^{\frac{n-1}{2}} \cdot x & \text{dla nieparzystego } n \end{cases} \quad (5.1.2)$$

Z liniowej liczby mnożeń zeszlśmy do logarytmicznej liczby mnożeń.

$$T(n) = 1 \cdot T\left(\frac{n}{2}\right) + \Theta(1) \quad (5.1.3)$$

$$T(n) = \Theta(\log n) \quad (5.1.4)$$

## 5.2 Wylczenie $n$ -tej liczby Fibonacciego

$$F_n = \begin{cases} 0 & n = 0 \\ 1 & n = 1 \\ F(n-1) + F(n-2), & n > 1 \end{cases} \quad (5.2.1)$$

Normalne wywołanie funkcji to  $\Theta(\varphi^n)$

Wykorzystajmy podejście bottom-up, liczymy i zapamiętujemy każdorazowo  $F_2, F_3, \dots, F_n$   
Osiągnęliśmy złożoność liniową  $\Theta(n)$

Istnieje jednak zwarty wzór na  $F(n) = \frac{1}{\sqrt{5}} \left( \frac{\varphi^n + \varphi^n}{2} \right)$  a to możemy policzyć logarytmicznie.

*Tu pojawiają się liczby - jak one się nazywały - (z sali) niewymierne.*

Istnieje macierz, która mnożona pozwala na policzenie  $n$ -tej liczby Fibonacciego.

$$\begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}^n = \begin{pmatrix} F_{n+1} & F_n \\ F_n & F_{n-1} \end{pmatrix} \quad (5.2.2)$$

Algorytm używający tego wzoru - połączony z szybkim potęgowaniem, ma złożoność  $\Theta(\log n)$ .

## 5.3 Mnożenie Liczb

- Input:  $x, y$  (liczby  $n$ -bitowe)
- Output:  $x \cdot y$

Standardowe mnożenie w słupku to  $\Theta(n^2)$  mnożeń i  $\Theta(n)$  dodawań.  
Założmy, że  $n$  jest parzyste:

$$x = x_L \cdot 2^{\frac{n}{2}} + x_R \quad (5.3.1)$$

$$y = y_L \cdot 2^{\frac{n}{2}} + y_R \quad (5.3.2)$$

$$x \cdot y = (x_L \cdot 2^{\frac{n}{2}} + x_R) \cdot (y_L \cdot 2^{\frac{n}{2}} + y_R) = \quad (5.3.3)$$

$$= x_L \cdot y_L \cdot 2^n + (x_L y_R + x_R y_L) \cdot 2^{\frac{n}{2}} + x_R y_R \quad (5.3.4)$$

$$T(n) = 4T\left(\frac{n}{2}\right) + \Theta(n) \quad (5.3.5)$$

$$a = 4, b = 2, d = 1 \quad (5.3.6)$$

$$\log_b a = \log_2 4 = 2 > 1 = d \quad (5.3.7)$$

$$T(n) = \Theta(n^2) \quad (5.3.8)$$

*Asymptotycznie nie zysaliśmy nic.*

Ten przypadek pokazuje, że czasami nie wystarczy bezmyślnie podzielić a potem scałić.

A co o tym myślał Gauss - tu jest dużo mnożeń - cztery.

$$(a + ib)(c + id) = ac - bd + i(bc + ad) \quad (5.3.9)$$

$$bc + ad = (a + b)(c + d) - ac - bd \quad (5.3.10)$$

Zobaczmy, że  $ac, bd$  są już policzone wyżej - zamiast 4 mnożeń, mamy 3 mnożenia.

$$x \cdot y = x_L y_L 2^n + ((x_L + x_R)(y_L + y_R) - x_L y_L - x_R y_R) + x_R y_R \quad (5.3.11)$$

Wykonujemy i zapamiętujemy mnożenia  $x_L y_L, x_R y_R, (x_L + x_R)(y_L + y_R)$  - zamiast 4 mnożeń, mamy 3 mnożenia.

$\Theta(n)$  - wynika z przeunięć bitowych oraz dodawań.

$$T(n) = 3T\left(\frac{n}{2}\right) + \Theta(n) \quad (5.3.12)$$

$$a = 3, b = 2, d = 1 \quad (5.3.13)$$

$$\log_b a = \log_2 3 > 1 = d \quad (5.3.14)$$

$$T(n) = \Theta(n^{\log_2 3}) = \Theta(n^{1.59}) \quad (5.3.15)$$

Najszybszy znany algorytm - na podstawie szybkiej transformaty fouriera  $\sim O(n \cdot \log n \cdot \log \log n)$

```
multiply(x, y)
  n = max {|x|, |y|}
  if n == 1 return x * y
  x_L, x_R = leftmost(ceil(n/2), x), rightmost(floor(n/2), x)
  y_L, y_R = leftmost(ceil(n/2), y), rightmost(floor(n/2), y)

  p1 = multiply(x_L, y_L)
```

```

p2 = multiply(x_R, y_R)
p3 = multiply(x_L + x_R, y_L + y_R)

return p1 << n + (p3 - p1 - p2) << ceil(n/2) + p2

```

Podobnie możemy mnożyć macierze.

## 5.4 Mnożenie macierzy

- Input:  $A, B$  -  $n$ -wymiarowe macierze
- Output:  $A \cdot B$

Naiwne mnożenie macierzy wykonuje  $\Theta(n^3)$  mnożeń.

Podzielmy macierz na 4 równe części:

$$\begin{pmatrix} A & B \\ C & D \end{pmatrix} \times \begin{pmatrix} E & F \\ G & H \end{pmatrix} = \begin{pmatrix} AE + BG & AF + BH \\ CE + DG & CF + DH \end{pmatrix} \quad (5.4.1)$$

$$T(n) = 8T\left(\frac{n}{2}\right) + O(n^2) \quad (5.4.2)$$

$$T(n) = O(n^3) \quad (5.4.3)$$

Znowu nic nie zyskał. Jesteśmy w stanie wyeliminować jedno mnożenie - osiągając ostatecznie  $\Theta(n^{\log_2 7}) \sim \Theta(n^{2.81})$ .

Algorytm state of the art -  $\Theta(n^2 \text{polylog}(n))$ .

## 5.5 Quick Sort

Algorytm na podział - scalanie już posortowanych. Pozwala na sortowanie w miejscu.

```

A[1..n]
|         |-----|         |
1         p         q         n

```

```

A[1..n]
|         |   <=   |         |   <   |         |
1         p         |pivot|         q         n

```

1. Podziel  $A[p..q]$  na dwie tablice:  $A[p..k-1]$ ,  $pivot$ ,  $A[k+1..q]$  takie, że:

$$\forall_{i \in [p..k-1]} A[i] \leq pivot, \forall_{j \in [k+1..q]} A[j] > pivot$$

2. Quicksort( $A, p, k-1$ )  
Quicksort( $A, k+1, q$ )

Przykład - weźmy nieposortowaną tablicę:

```

Quicksort(A,1,n)
[6, 1, 4, 3, 5, 7, 2, 8] # pivot = 6
->
[1, 4, 3, 5, 2, 6, 7, 8]
.
Quicksort(A,1,5)
Quicksort(A,7,8) ->
[1, 4, 3, 2, 5, 6, 7, 8] # pivot = 1
. . .
Quicksort(A,2,5) ->
[1, 3, 2, 4, 5, 6, 7, 8] # pivot = 4
. . .
Quicksort(A,2,3) ->
[1, 2, 3, 4, 5, 6, 7, 8] # pivot = 3
. . . . .

```

## 6 Lecture VI - Quicksort

Rozważmy algorytmy służące do dzielenia tablicy w Quicksorcie

### 6.1 Lomuto Partition

```

Lomuto Partition(A, p, q) # A[p..q]
    pivot = A[p]
    i = p
    for j = p + 1 to q
        if A[j] <= pivot # expensive |A[p..q]| = n, then (n-1) comparisons ~ Theta(n)
            i = i + 1
            swap (A[i], [j]) # expensive, but if dependent
    swap (A[i], A[p]) # pivot in between A[p..i] and A[i+1..q]
    return i

```

```

A
|*| <= pivot |i| pivot < |j| ? |
p                                     q

```

We either put the ? element in the '<= pivot' part, or '> pivot' part

```

A
| <= pivot | * | pivot < |
p                                     q

```

Example

```

6, 10, 13, 5, 8, 3, 2, 11
* i         j

```

```

swap(5,10)

6, 5, 13, 10, 8, 3, 2, 11
* i           j

do nothing

6, 5, 13, 10, 8, 3, 2, 11
* i           j

swap(3, 13)

6, 5, 3, 10, 8, 13, 2, 11
* i           j

6, 5, 3, 2, 8, 13, 10, 11
* i           j

6, 5, 3, 2, 8, 13, 10, 11
* i           j

swap(6, 2)

2, 5, 3, 6, 8, 13, 10, 11
* i           j

return i = 3

```

Biorąc pod uwagę, że dokonujemy  $n - 1$  porównań, złożoność Lomuto Partition wynosi  $\Theta(n)$ .

## 6.2 Hoare Partition

```

Hoare Partition(A, p, q) # A[p..q]
    pivot = A[floor((p+q)/2)]
    i = p - 1
    j = q + 1
    while True
        do
            i++
            while A[i] < pivot

        do
            j--
            while A[j] > pivot

        if i >= j return j
        swap(A[i], A[j])

```

\* - pivot

Example

```

6, 10, 13, 5, 8, 3, 2, 11
i p      *      q j
i      *      j      # swap(6, 2)

2, 10, 13, 5, 8, 3, 6, 11
i      *      j      # swap(10, 3)

2, 3, 13, 5, 8, 10, 6, 11
      *

2, 3, 13, 5, 8, 10, 6, 11
i j      # swap (13, 5)

2, 3, 5, 13, 8, 10, 6, 11
      *
      j i

```

```

A
| <= pivot | < pivot |
p      j      q

```

return j

W Hoare Partition tracimy pivot który może ulec przesunięciu. Porównań robimy więcej o stałą  $n \pm c$ ,  $c = 1$ . Złożoność  $\Theta(n)$  - zdecydowanie mniej swapów, 2-3 razy mniej niż Lomuto partition.

```

QS(A,p,q)
  if p < q
    r = Partition(A,p,q)
    QS(A,p,r-1)
    QS(A,r+1,q)

```

### 6.3 Worst Case Analysis for QS

Najgorzej będzie jak każdorazowo będziemy nierówno dzielić po 1-szym elemencie (odwrotnie posortowana tablica).

```

      cn
     /  \
  Theta(1) c(n-1)
       /   \
    Theta(1) c(n-2)
           ...
        /     \
    Theta(1)  Theta(1)

```

$$T(n) = T(n-1) + T(0) + \Theta(n) \quad (6.3.1)$$

$$T(n) = T(n-1) + \Theta(n) \leq \sum_{i=0}^n c(n-i) + \Theta(1) = \quad (6.3.2)$$

$$= c \sum_{i=0}^n (n-i) + \Theta(n) = \quad (6.3.3)$$

$$= c \frac{(n)(n+1)}{2} + \Theta(n) = \quad (6.3.4)$$

$$= O(n^2) \quad (6.3.5)$$

## 6.4 Best case Analysis for QS

Najlepiej będzie jak dzielimy na pół.


$$T(n) = T\left(\frac{n}{2}\right) + T\left(\frac{n}{2}\right) + \Theta(n) \quad (6.4.1)$$

$$T(n) = 2T\left(\frac{n}{2}\right) + \Theta(n) \quad (6.4.2)$$

$$T(n) = \Theta(n \log n) \quad (6.4.3)$$

## 6.5 Specific case analysis for QS

$$T(n) = T\left(\frac{n}{10}\right) + T\left(\frac{9n}{10}\right) + \Theta(n) \quad (6.5.1)$$



Po zsumowaniu każde piętro będzie miało koszt  $cn$ . Zchodzimy końca wysokości drzewa.

$$\left(\frac{9}{10}\right)^h n = 1 \quad (6.5.2)$$

$$n = \left(\frac{10}{9}\right)^h \quad (6.5.3)$$

$$h = \log_{\frac{10}{9}} n \quad (6.5.4)$$



## 6.6 Best/Worst case analysis for QS - Intuition

$$L(n) = 2U\left(\frac{n}{2}\right) + \Theta(n) \quad (6.6.1)$$

$$U(n) = L(n-1) + L(0) + \Theta(n) \quad (6.6.2)$$

$$(6.6.3)$$

Zatem rozwiążmy układ równań:

$$L(n) = 2\left(L\left(\frac{n}{2} - 1\right) + \Theta(n)\right) + \Theta(n) \quad (6.6.4)$$

$$L(n) = 2L\left(\frac{n}{2} - 1\right) + \Theta(n) \quad (6.6.5)$$

$$L(n) = \Theta(n \log n) \quad (6.6.6)$$

## 6.7 Average case analysis for QS

Rozkład  $T_n$  nie jest znany do dziś.

Zapiszmy dla  $0 \leq k \leq n-1$ :

$$T_n = \# \text{ porównań elementów sortowanej tablicy, } |A| = n \quad (6.7.1)$$

$$X_k(n) = \begin{cases} 1 & \text{jeśli partition podzieli tablicę n-elementową na (k, n-k-1)} \\ 0 & \text{w p.p.} \end{cases} \quad (6.7.2)$$

Możemy wyznaczyć wartość oczekiwaną zmiennej losowej  $X_k$ :

$$E(X_k) = 1 \cdot P(X_k = 1) + 0 \cdot P(X_k = 0) = 1 \cdot P(X_k = 1) = \frac{(n-1)!}{n!} = \frac{1}{n} \quad (6.7.3)$$

Zapiszmy wobec tego równanie na  $T_n$ , uwzględniające wszystkie przypadki:

$$T_n =^{distr.} \begin{cases} T_0 + T_{n-1} + n - 1 & \text{if (0,n-1) - split} \\ T_1 + T_{n-2} + n - 1 & \text{if (1,n-2) - split} \\ \vdots \\ T_k + T_{n-1-k} + n - 1 & \text{if (k,n-k-1) - split} \\ T_{n-1} + T_0 + n - 1 & \text{if (n-1,0) - split} \end{cases} \quad (6.7.4)$$

$$T_n =^{distr.} \sum_{k=0}^{n-1} X_k(T_k + T_{n-k-1} + n - 1) \quad (6.7.5)$$

$$E(T_n) = E\left(\sum_{k=0}^{n-1} X_k(T_k + T_{n-k-1} + n - 1)\right) = \quad (6.7.6)$$

$$E(T_n) = \sum_{k=0}^{n-1} E(X_k(T_k + T_{n-k-1} + n - 1)) = \quad (6.7.7)$$

$$E(T_n) = \sum_{k=0}^{n-1} E(X_k) \cdot E(T_k + T_{n-k-1} + n - 1) = \quad (6.7.8)$$

$$E(T_n) = \frac{1}{n} \sum_{k=0}^{n-1} E(T_k) + E(T_{n-k-1}) + n - 1 = \quad (6.7.9)$$

$$E(T_n) = \frac{1}{n} \left( \sum_{k=0}^{n-1} E(T_k) + \sum_{k=0}^{n-1} E(T_{n-k-1}) + \sum_{k=0}^{n-1} n - 1 \right) = \quad (6.7.10)$$

$$E(T_n) = \frac{1}{n} \sum_{k=0}^{n-1} E(T_k) + \frac{1}{n} \sum_{k=0}^{n-1} E(T_{n-k-1}) + \frac{1}{n} \sum_{k=0}^{n-1} n - 1 = \quad (6.7.11)$$

$$E(T_n) = \frac{1}{n} \sum_{k=0}^{n-1} E(T_k) + \frac{1}{n} \sum_{k=0}^{n-1} E(T_{n-k-1}) + n - 1 \quad (6.7.12)$$

$$E(T_n) = \frac{2}{n} \sum_{k=0}^{n-1} E(T_k) + n - 1 \quad (6.7.13)$$

Podstawmy dla wygody  $t_n = E(T_n)$ :

$$t_n = \frac{2}{n} \sum_{k=0}^{n-1} t_k + n - 1 \quad \text{rekurencja z pełną historią} \quad (6.7.14)$$

Możemy usunąć historię odejmując od siebie kolejne wyrazy rekurencji.

$$nt_n = 2 \sum_{k=0}^{n-1} t_k + (n-1)n \quad (6.7.15)$$

$$(n-1)t_{n-1} = 2 \sum_{k=0}^{n-2} t_k + (n-2)(n-1) \quad (6.7.16)$$

Zachodzi odejmowanie stronami

$$nt_n - (n-1)t_{n-1} = 2 \sum_{k=0}^{n-1} t_k + (n-1)n - 2 \sum_{k=0}^{n-2} t_k - (n-2)(n-1) \quad (6.7.17)$$

$$nt_n - (n-1)t_{n-1} = 2t_{n-1} + 2(n-1) \quad (6.7.18)$$

$$nt_n = (n+1)t_{n-1} + 2(n-1) \quad (6.7.19)$$

$$\frac{t_n}{n+1} = \frac{t_{n-1}}{n} + 2 \frac{n-1}{n(n+1)} \quad (6.7.20)$$

Dokonajmy podstawienia  $f_n = \frac{t_n}{n+1}$ ,  $f_0 = 0$ ,  $f_1 = 0$ :

$$f_n = f_{n-1} + 2 \frac{n-1}{n(n+1)}, f_0, f_1 = 0 \quad (6.7.21)$$

$$f_n = 2 \sum_{k=1}^n \frac{k-1}{k(k+1)} = \quad (6.7.22)$$

$$f_n = 2 \sum_{k=1}^n \frac{2}{k+1} - \frac{1}{k} = \quad (6.7.23)$$

$$f_n = 4 \sum_{k=1}^n \frac{1}{k+1} - 2 \sum_{k=1}^n \frac{1}{k} = \quad (6.7.24)$$

$$f_n = 4(H_{n+1} - 1) - 2H_n \quad (6.7.25)$$

$$f_n = 4 \left( H_n + \frac{1}{n+1} - 1 \right) - 2H_n \quad (6.7.26)$$

$$f_n = 2H_n - 4 + \frac{4}{n+1} \quad (6.7.27)$$

Wróćmy z podstawienia  $t_n = (n+1)f_n$ :

$$E(T_n) = t_n = (n+1)f_n = 2nH_n + 2H_n - 4(n+1) + 4 \quad (6.7.28)$$

$$H_n = \ln n + \gamma + \frac{1}{2n} + \Theta\left(\frac{1}{n^2}\right) \quad (6.7.29)$$

Widzimy, że wiodący czynnik  $T_n = 2n \ln n + \Theta(n)$ . Wiemy dlaczego QS jest dobry - średnio wykona  $2n \ln n$  porównań asymptotycznie.

## 7 Lecture VII - Quicksort - further analysis

$| \leq |p| < \dots \leq |q| < |$

Możemy wyróżnić dwa pivoty, w obrębie których prowadzimy sortowanie. To wymaga stworzenia nowego algorytmu partition.

1. 1975 Sedgewick (liczba porównań w dual-pivot partition)

$$E(\# \text{ dual pivot partition}) \sim \frac{16}{9}n \implies E(\# \text{ QS}) \sim \frac{32}{15}n \log n$$

2. 2009 Yaroslavsky, Bentley, Block - Dual pivot quick sort

3. 2012 Sebastian Wild, Nebel

$$E(\# \text{ dual pivot partition}) \sim \frac{19}{12}n \implies E(\# \text{ QS}) \sim 1.9n \log n$$

4. 2015 Aumuller Dietzfelbinger - zaprezentowali strategię count oraz pokazali jej optymalność:

$$E(\# \text{ count partition}) \sim \frac{3}{2}n \implies E(\# \text{ QS}) \sim 1.8n \log n$$

## 7.1 Strategia Count

Zakładamy  $p < q$  - rozpatrujemy wartość oczekiwaną, ponieważ jedynie pierwsze sprawdzenie z pivotem jest wymagane.

$$\begin{array}{ccccccc} 1 & & s_{i-1} & & & & l_{i-1} \\ | & | & \leq p & | < \dots < & | q & | < & | i | & ? & | \\ & a & & & & & & & b \end{array}$$

Rozpatrzmy  $i$ -ty element w podziale (pamiętając, że  $p < q$ ):

- jeśli  $s_{i-1} \geq l_{i-1}$  to porównujemy kolejny  $A[i]$  najpierw z  $p$ , a potem ewentualnie z  $q$  (jeśli  $A[i] < p$  to nie musimy porównywać z  $q$ )
- jeśli  $s_{i-1} < l_{i-1}$  to  $A[i]$  porównujemy najpierw z  $q$ , a potem ewentualnie z  $p$

$$E(T_n) = E(P_n) = \frac{1}{\binom{n}{2}} \sum_{1 \leq p < q \leq n} E(T_{p-1}) + E(T_{q-p-1}) + E(T_q) \quad (7.1.1)$$

Tim Peters - Tim-sort - modyfikacja merge-sorta, wyznaczmy posortowane podciągi przed merge-m, mergeujemy podobnej wielkości tablice - specjalna polityka merge-owania.  
... ograniczenie dolne, counting sort w czasie liniowym zbioru wielkości  $O(n)$

## 7.2 Counting Sort

Counting sort<sup>1</sup> zakłada, że każdy z wejściowych elementów mieści się w przedziale  $[0, k]$ , dla pewnego  $k \in \mathbb{Z}$ . Gdy  $k = O(n)$ , to złożoność algorytmu wynosi  $\Theta(n + k) = \Theta(n)$ . Do jego wykonania potrzebujemy tablicy pomocniczej.

```
COUNTING-SORT(A, B, k)
let C[0..k] be a new array
for i = 0..k
    C[i] = 0
for j = 1..length[A]
    C[A[j]] = C[A[j]] + 1
for i = 1..k
    C[i] = C[i] + C[i - 1]
for j = length[A]..1
    B[C[A[j]]] = A[j]
    C[A[j]] = C[A[j]] - 1
```

Counting sort ma własność stabilności - zachowuje elementy tej samej wartości w kolejności, w jakiej występują w tablicy wejściowej.

<sup>1</sup>Cormen (194-196) - Chapter 8 - Sorting in Linear Time - 8.2 Counting Sort

### 7.3 Radix Sort

Radix Sort polega na sortowaniu liczb w systemie pozycyjnym, przy pomocy innego stabilnego sortowania.

```
RADIX-SORT(A, d)
for i = 1..d
    COUNTING-SORT(A, i)
```

## 8 Lecture VIII

### 8.1 Poprawność Radix Sort

Indukcja po  $t$ -numer cyfry.

1. Jeśli liczby 1-cyfrowe to z poprawności Counting Sorta ok.
2. Załóżmy indukcyjnie Radix Sort jest poprawny do  $t - 1$  cyfry.
3. Krok indukcyjny  $t$ -ta dwóch liczb jest taka sama. To z założenia indukcyjnego dalej oraz stable property Counting Sorta liczby do  $t$ -tej cyfry dalej pozostaną posortowane.  $t$ -ta cyfra różna: z poprawności counting sorta OK.

### 8.2 Złożoność obliczeniowa Radix Sort

| $r$ -bitowy kawałek|  $r'b \dots$  |  $r'b \dots$  |  $\dots$  |  $r'b \dots$  |  
 $b$ -bitów dzielimy na kawałki (cyfry w podstawie  $r$ )

Mamy  $n$ ,  $b$ -bitowych liczb, które dzielię na ( $r$ -bitowe cyfry  $\frac{b}{r}$  takich cyfr).  
Cyfry są z  $|\{0, \dots, 2^r - 1\}| = 2^r$ . Zatem pojedynczy counting sort  $n$ -liczb względem jednej cyfry to:

$$O(n + 2^r) \quad (8.2.1)$$

Zatem Radix Sort będzie miał złożoność obliczeniową

$$O\left(\frac{b}{r}(n + 2^r)\right) \quad (8.2.2)$$

W celu ustalenia najlepszego  $r$  - minimalnego  $f$  - wykorzystamy funkcję  $W$ -Lamberta

$$f(r) = \frac{b}{r}(n + 2^r) \quad (8.2.3)$$

Zaproponujmy funkcję  $r = \log n$ , wtedy:

$$O\left(\frac{b}{\log n}(n + 2^{\log n})\right) = O\left(\frac{b \cdot n}{\log n}\right) = \quad (8.2.4)$$

$$(8.2.5)$$

Założmy, że zbiór sortowanych elementów to:

$$\{0, \dots, n^d - 1\} - \text{do tego zbioru należą } b\text{-bitowe sortowane liczby} \quad (8.2.6)$$

Wtedy maksymalne  $b = \log n^d = d \log n$ :

$$(\dots) = O\left(\frac{dn \log n}{\log n}\right) = O(d \cdot n) \quad (8.2.7)$$

### 8.3 Statystyki pozycyjne

**Definition. Statystyka pozycyjna.**  $k$ -tą statystykę pozycyjną nazywamy  $k$ -tą najmniejszą wartość z danego zbioru.

- Co się dzieje, jeśli  $k = 1 \rightarrow \Theta(n)$ .
- Co się dzieje, jeśli  $k = n \rightarrow \Theta(n)$ .
- Co się dzieje, jeśli  $k = \lfloor \frac{n-1}{2} \rfloor \vee \lfloor \frac{n+1}{2} \rfloor \rightarrow$  sortowanie

### 8.4 RandomSelect(A,p,q,i)

Nazwa RandomSelect bierze się z tego, że wybieramy losowy element jako pivot.  $p$  to indeks początkowy,  $q$  to indeks końcowy,  $i$  to numer zadanej statystyki pozycyjnej.

```
RandomSelect(A, p, q, i)
  IF p == q return A[p]
  r = Rand_Partition(A,p,q) # jako pivota przyjmieny losowy element
  k = r - p + 1
  IF i == k return A[r]
  IF i < k return RandomSelect(A, p, r-1, i)
  ELSE return RandomSelect(A, r+1, q, i-k)
```

**Przykład.** Szukajmy 4-tej statystyki pozycyjnej (Pivot oznaczamy '\*'):

6, 10, 13, 5, 8, 3, 2, 11  
\*

Po podziale względem pivota:

6, 5, 8, 3, 2, 10, 13, 11      RandomSelect(A, 1, 8, 4), r = 6, k = 6 - 1 + 1 = 6  
\*

Bierzemy lewą część:

2, 3, 6, 5, 8      RandomSelect(A, 1, 5, 4)  
\*

Pivot index: r = 2, k = 2 - 1 + 1 = 2

I dalej:

6, 5, 8      RandomSelect(A, 3, 5, 2)  
\*

Pivot index: r = 4, k = 4 - 3 + 1 = 2

Zwracamy czwarty element posortowanej tablicy **6** (dla sprawdzenia: posortowana tablica):

2, 3, 5, 6, 8, 10, 11, 13

## 8.5 Best Case dla RandomSelect

Każdorazowo dzielimy tablicę na pół.

$$T(n) = 1 \cdot T\left(\frac{n}{2}\right) + \Theta(n) \quad \text{n to partition} \quad (8.5.1)$$

$$a = 1, b = 2, d = 1, \log_2 1 = 0 < 1 \implies \quad (8.5.2)$$

$$T(n) = \Theta(n) \quad (8.5.3)$$

## 8.6 Worst Case dla RandomSelect

Każdorazowo wybieramy pivot tak, że dzielimy tablicę na  $n - 1$  i 0-elementową część.

$$T(n) = 1T(n - 1) + \Theta(n) \quad \text{partition is unfortunate} \quad (8.6.1)$$

$$T(n) = O(n^2) \quad (8.6.2)$$

## 8.7 Average Case dla RandomSelect

$$E(T_n) = (n - 1) + \frac{2}{n} \sum_{k=\lceil \frac{n}{2} \rceil}^{n-1} E(T_k) \quad (8.7.1)$$

Możemy zapisać (rozbicia na  $k$  i  $n - k - 1$ , z których bierzemy tylko jedno z nich). Wiemy, że  $n - 1$  to koszt Partition, zatem:

$$T_n = \begin{cases} T_{n-1} + n - 1 : (0, n - 1) \\ T_{n-2} + n - 1 : (1, n - 2) \\ \vdots \\ T_{\lceil \frac{n}{2} \rceil} + n - 1 : (\lfloor \frac{n}{2} \rfloor, \lceil \frac{n}{2} \rceil) \end{cases} \quad (8.7.2)$$

Można to rozwiązać indukcyjnie, aby wykazać, że  $E(T_n) = \Theta(n)$ .

*Uwaga. Te przekształcenia wykonałem po wykładzie*

Wiemy, że ograniczenie dolne na  $T_n$  wynosi  $\Omega(n)$ , ponieważ  $n - 1 = O(n)$  to sam koszt dla Partition. Ustalmy ograniczenie górne metodą, którą wykorzystaliśmy przy analizie Quick Sorta. Mamy:

$$X_k = \begin{cases} 1 & \text{jeśli partition podzieli tablicę n-elementową na (k, n-k-1)} \\ 0 & \text{w p.p.} \end{cases} \quad (8.7.3)$$

Zauważmy, że  $k \in \{0, \dots, \frac{n}{2}\}$ , zatem  $E(X_k) = \frac{2}{n}$ . Zapiszmy następnie:

$$T_n = \sum_{k=0}^{\frac{n}{2}} X_k (T_{n-k-1} + n - 1) \quad (8.7.4)$$

$$T_n = \frac{2}{n} \cdot \left( \sum_{k=0}^{\lfloor \frac{n}{2} \rfloor} T_{n-k-1} + \sum_{k=0}^{\lfloor \frac{n}{2} \rfloor} (n - 1) \right) \quad (8.7.5)$$

Widzimy, że druga suma jest  $O(n)$ , zatem rozważmy dalej pierwszą część:

$$T_n = \frac{2}{n} \sum_{k=\frac{n}{2}-1}^{n-1} T_k + O(n) \quad (8.7.6)$$

$$(8.7.7)$$

Wystarczy pokazać, że pierwszy człon również jest  $O(n)$ . Zróbmy to indukcyjnie.

$$S_n = \frac{2}{n} \sum_{k=\frac{n}{2}}^{n-1} T_k \quad (8.7.8)$$

$$(8.7.9)$$

Przypadek bazowy  $S_1 = T_1 = O(1)$

Założenie indukcyjne  $\forall_{k < n} S_k \leq ck$ . Przeprowadźmy krok indukcyjny:

$$S_n = \frac{2}{n} \sum_{k=\frac{n}{2}}^{n-1} T_k \leq \frac{2}{n} \sum_{k=\frac{n}{2}}^{n-1} ck = \quad (8.7.10)$$

$$= \frac{2c}{n} \left( \sum_{k=0}^{n-1} k - \sum_{k=0}^{\frac{n}{2}-1} k \right) = \quad (8.7.11)$$

$$= \frac{2c}{n} \left( \frac{n(n-1)}{2} - \frac{n(n+2)}{8} \right) \leq \quad (8.7.12)$$

$$\leq \frac{2c}{n} \left( \frac{1}{8} n(3n-2) \right) = \quad (8.7.13)$$

$$= \frac{3}{4} cn \leq cn \quad (8.7.14)$$

Zatem  $S_n \leq cn$  i ostatecznie  $T_n = \Theta(n)$ .

## 8.8 Select(A,p,q,i)

Algorytm ma duże podobieństwo z RandomSelect. Nie wybieramy losowego pivota - tylko inteligentnie. Niech  $|A[p..q]| = n$ .

1. Dzielimy  $A[p..q]$  na  $\lfloor \frac{n}{5} \rfloor$  pięć elementowych części oraz ostatnią część rozmiaru  $\leq 5$ .
2. Sortujemy te grupy i wybieramy z każdej z nich medianę.  $M = \{m_1, m_2, \dots, m_{\lfloor \frac{n}{5} \rfloor}\}$
3. Znajdujemy medianę  $M$  :  $Select(M, 1, \lceil \frac{n}{5} \rceil, \lfloor \frac{\lceil \frac{n}{5} \rceil}{2} \rfloor) \implies x$ .  $M$  wygląda jak osobna tablica - da się to zrobić in place.
4. Ustaw  $x$  (medianę median) jako pivot Partition( $A, p, q$ ) Dalej tak samo jak Random-Select, oczywiście odpaląc rekurencyjnie Select.

Dzielimy na 5 części

```
|.....|.....|.....|.....|.....|
sort 5-el części, wyzn medianę
```



```

max
| . | . | . | . | . |
| . | . | . | . | . |
| .m| .m| .m| .m| .m|
| . | . | . | . | . |
| . | . | . | . | . |
min

```

Zapuszczam selecta na M, |M|=5

Pierwsze dwa kroki algorytmu zajmą  $O(n)$  - podzielenie tablicy i posortowanie piętek.  
Późniejsze kroki są dane jako rekurencja:

$$T(n) = T\left(\left\lceil \frac{n}{5} \right\rceil\right) + T(?) + O(n) \quad (? \text{ na następnym wykładzie}) \quad (8.8.1)$$

## 9 Lecture IX - Select

1. Dziel wejściową tablicę na 5-elementowe podtablice i znajdź ich mediany -  $\Theta(n)$
2. Select (...) - znajdź medianę median. -  $T\left(\left\lceil \frac{n}{5} \right\rceil\right)$
3. Użyj mediany median jako pivot w Partition -  $\Theta(n)$
4. Idź do lewej albo prawej podtablicy w zależności od indeksu pivot i uszkaniej statystyki pozycyjnej.  $T(?)$

$$T(n) = T\left(\left\lceil \frac{n}{5} \right\rceil\right) + T(?) + \Theta(n) \quad (9.0.1)$$

Dzielimy na 5 części

```

|.....|.....|.....|.....|.....|
sort 5-el części, wyzn medianę

```

```

max
| .w| .w| .w| . | . |
| .w| .w| .w| . | . |
| .w> w> .M> .s> .s|
| . | . | .s| .s| .s|
| . | . | .s| .s| .s|
min

```

M - mediana median (zakładamy porządek)

w - większe od mediany median (forall i : M < w\_i)

s - mniejsze od mediany median (forall i : M < s\_i)

". " - części o których nic nie powiemy

Wszystkich piętek jest  $\text{ceil}(n/5)$

Wartości mniejszych od M jest  $3 \cdot (1/2 \text{ ceil}(n/5) - 1 - 1)$  (minus skrajna oraz mediana median)

Każda piątka kontrubuuje, ale nie liczymy skrajnych piątek - ponieważ wyznaczamy ograniczenie

```
| .w| .w| .w| . | . | . |
| .w| .w| .w| . | . | . |
| .w> w> .M> .l> .l | .s|
| . | . | .s| .l| .l | .s|
| . | . | .s| .l| .l | .s|
```

l - zliczamy

s - ignorujemy (można lepiej, ale nie trzeba)

-||- większych jest  $1/2 \text{ ceil}(n/5)$

$$\text{Wartości mniejszych od M} \geq \left( \frac{1}{2} \lceil \frac{n}{5} \rceil - 1 - 1 \right) \cdot 3 \geq \quad (9.0.2)$$

$$\geq \frac{3}{10}n - 6 \quad (9.0.3)$$

Prezentowana tablica

|  $3/10 n - 6$  | M |  $n - (3/10 m - 6) - 1 = 7/10n + 5$  |

Zatem

$$T(n) \geq T\left(\lceil \frac{n}{5} \rceil\right) + T\left(\frac{7}{10}n + 5\right) + \Theta(n) \quad (9.0.4)$$

$$\frac{3}{4}n \geq \frac{7}{10}n + 5 \quad \text{dla } n > 100 \quad (9.0.5)$$

$$T(n) \leq T\left(\frac{n}{5}\right) + T\left(\frac{3}{4}n\right) + \Theta(n) \quad (9.0.6)$$

Niech  $T(1) = \Theta(1)$ . Chcemy pokazać, że  $T(n) = \Theta(n)$ .

Założenie indukcyjne:

$$(\forall k < n) T(k) \leq ck \quad (9.0.7)$$

Krok indukcyjny

$$T(n) \leq T\left(\frac{n}{5}\right) + T\left(\frac{3}{4}n\right) + \Theta(n) \leq c \cdot \frac{n}{5} + c \cdot \frac{3}{4}n + \Theta(n) < \quad (9.0.8)$$

$$c \cdot \frac{19}{20}n + \Theta(n) < \quad (9.0.9)$$

$$cn - \frac{1}{20}cn + \Theta(n) < \quad (9.0.10)$$

$$cn - \frac{1}{20}cn + dn < \quad (9.0.11)$$

$$\text{wyznaczymy } \left(-\frac{1}{20}cn + dn\right) \leq 0 \quad (9.0.12)$$

$$\left(-\frac{1}{20}c + d\right) \leq 0 \quad (9.0.13)$$

$$c \geq 20d \quad (9.0.14)$$

Zatem istnieje takie  $c$ , że nierówność jest prawdziwa, więc:

$$T(n) = O(n) \quad (9.0.15)$$

*Cel analizy algorytmu - pokazać że rekurencje tego typu mogą się zdarzyć*

## 9.1 Struktury Danych

Interesują nas struktury danych, które implementują *Set* interface.  
Ma to być zbiór dynamiczny - możemy dodawać oraz usuwać elementy.  
Zakładamy **comparison model**.

Podstawowe metody *Set* interface:

1. *build(A)* - buduje "set" z danych zawartych w  $A$ . Mamy  $a \in A$ ,  $a.key$  - klucz identyfikujący element.
2. *length(A)* - zwraca moc zbioru  $A$
3. *find(k)* - zwraca element  $a \in A$  taki że  $a.key = k$  lub null
4. *insert(a)* - dodaj element  $a$  do zbioru  $A$
5. *delete(k)* - usuń (czasem zwróć) element zbioru  $A$  o kluczu  $k$
6. *find\_min()*, *find\_max()*, *find\_prev(k)*, *find\_next(k)* (*find n*), *list\_ordered()* - zwróć element o najmniejszym lub największym kluczu  $k$ .

Struktura	Build	Find	Insert/Delete	Find mM	Find pn	List _ordered
Unsorted Array	$\Theta(n)$	$\Theta(n)$	$\Theta(n)$	$\Theta(n)$	$\Theta(n)$	$\Theta(n \log n)$
Sorted Array	$\Theta(n \log n)$	$\Theta(\log(n))$	$\Theta(n)$	$\Theta(1)$	$\Theta(\log n)$	$\Theta(n)$
Linked List	$\Theta(n)$	$\Theta(n)$	insert $\Theta(1)$ , delete $\Theta(n)$	$\Theta(n)$	$\Theta(n)$	$\Theta(n \log n)$
BST	$\Theta()$	$\Theta()$	$\Theta()$	$\Theta()$	$\Theta()$	$\Theta(n)$

Table 1: Porównanie różnych struktur danych

## 9.2 Binary Search Tree

Drzewo przeszukiwań binarnych


Single Tree Node

```
| parent |
| left | key | values | right |
```

"0" represents a node

```

      0 5
     /  \
    3 0   0 10
   /  \  /  \
  1 0  8 0  0 12
```



```
InorderTreeWalk(p)
1, 3, 5, 8, 10, 12, 15, 16, 18
```

Zakładamy interfejs zbioru (klucze się nie powtarzają). W przeciwnym przypadku zakładamy multizbiór.

BST Property. Niech  $x \in T$ ,  $x$  jest węzłem drzewa  $T$  (BST), wtedy:

- każdy  $y \in x.left$  ma  $y.key < x.key$
- każdy  $y \in x.right$  ma  $y.key > x.key$

### 9.3 Operacje na BST

```
InorderTreeWalk (x\in T)
  if (x != null)
    InorderTreeWalk (x.left)
    print(x)
    InorderTreeWalk (x.right)
```

$$T(n) = T(k) + \Theta(1) + T(n - 1 - k) \quad (9.3.1)$$

Pokażmy, że  $T(n) = \Theta(n)$

Założenie indukcyjne:  $\forall k < n \quad T(k) \leq ck$  Krok indukcyjny:

$$T(n) = T(j) + \Theta(1) + T(n - 1 - j) \leq \quad (9.3.2)$$

$$cj + \Theta(1) + c(n - 1 - j) = \quad (9.3.3)$$

$$= cn - c - \Theta(1) \leq cn \quad (9.3.4)$$

Zatem  $T(n) = O(n)$ , musimy przejść  $n$  elementów, zatem ograniczenie dolne również wynosi  $n$ , więc  $T(n) = \Theta(n)$ .

```
TreeSearch(x, k)
  if x == null OR k == x.key
    return x
  if k < x.key
    return TreeSearch(x.left, k)
  else
    return TreeSearch(x.right, k)
```

```
TreeMinimum(x) -> T(n) = O(h)
```

```
TreeMaximum(x) -> T(n) = O(h)
```

```

TreeSuccessor(x)
    if x.right != null
        return TreeMinimum(x.right)
    y = x.p
    while y != null AND x == y.right
        x = y
        y = y.p
    return y

```

TreeSuccessor(x) ->  $T(n) = O(h)$

## 10 Lecture X

TreeInsert(x, el)  $\sim O(h)$  - nie było kodu na wykładzie :/

```

TreeInsert(x, el)
    if x == null
        return el
    if el.key < x.key
        x.left = TreeInsert(x.left, el)
        x.left.p = x
    else
        x.right = TreeInsert(x.right, el)
        x.right.p = x
    return x

```

TreeDelete(x)

1. x jest liściem
  - zwolnij pamięć zajmowaną przez x
  - ustaw wskaźnik jego ojca (na niego na null)
2. x ma jedno poddrzewo
  - x ma syna v to
    - zwalniamy pamięć x
    - ojciec x wskazuje na v
    - v.p wskazuje na x.p
3. x ma dwa poddrzewa
  - znajdź następnik x->y
  - zastąp dane x danymi y
  - skasuj y


### 10.1 Wysokość Drzewa BST

Wysokość drzewa to liczba krawędzi wzdłuż najdłuższej ścieżki od korzenia do liścia.


$$h = (n - 1) = O(n) \quad (10.1.1)$$

Worst Case

0 1



Best Case




**Definition. Drzewo zbalansowane.** Mówimy, że drzewo jest zbalansowane jeśli jego wysokość to  $O(\log n)$ .

## 10.2 BST\_Sort

Dodaj wszystkie elementy tablicy A do drzewa BST. InorderTreeWalk(T)

3 7 5 6 8 1 2



QS



Widzimy znaczące podobieństwo w porównaniach.

$$E(\text{Time}(\text{BST\_SORT})) = E(\text{Time}(\text{QuickSort})) = \Theta(n \log n) \quad (10.2.1)$$

$$\text{Time}(\text{BST\_SORT}) = \sum_{x \in T} \text{depth}(x) \quad (10.2.2)$$

$$E\left(\sum_{x \in T} \text{depth}(x)\right) = \Theta(n \log n) \quad (10.2.3)$$

$$E\left(\frac{1}{n} \sum_{x \in T} \text{depth}(x)\right) = \Theta(\log n) \quad (10.2.4)$$

$$\text{średnia głębokość węzła w losowym drzewie BST} \quad (10.2.5)$$

$$h = \max_{x \in T} \{\text{depth}(x)\} \quad (10.2.6)$$

$$\frac{1}{n} \sum_{x \in T} \text{depth}(x) \leq \frac{1}{n} ((n - \sqrt{n})(\log n) + \sqrt{n} \cdot \sqrt{n}) \leq \log n + 1 = O(\log n), \text{ ale } h = O(\sqrt{n}) \quad (10.2.7)$$

**Theorem. Wysokość BST.** Niech  $T$  będzie losowym drzewem BST o  $n$ -węzłach, wtedy:


$$E(h(T)) \leq 3 \log_2 n + o(\log n) \quad (10.2.8)$$

*Proof.* Nierówność Jensena jeśli  $f$ -wypukła, to:

$$f(E(X)) \leq E(f(X)) \quad (10.2.9)$$

1. Nierówność Jensena
2. Zamiast analizować zmienną losową  $H_n$ , będziemy się zajmować  $Y_n = 2^{H_n}$
3. Pokażemy, że  $E(Y_n) = O(n^3)$
4.  $2^{E(H_n)} \leq E(2^{H_n}) = E(Y_n) = O(n^3)$
5.  $E(H_n) = 3 \log_2 n + o(\log n)$

Pokażmy, że  $E(Y_n) = O(n^3)$ .



Zakładając że korzeń tworzy  $(k-1, n-k)$ -split:

$$H_n =^d = 1 + \max\{H_{k-1}, H_{n-k}\} \quad (10.2.10)$$

$$Y_n =^d = 2 \max\{Y_{k-1}, Y_{n-k}\} \quad (10.2.11)$$

$$Z_{n,k} =^d = \begin{cases} 1 & \text{jesli korzeń n-el drzewa wykonuje } (k-1, n-k)\text{-split} \\ 0 & \text{w p.p.} \end{cases} \quad (10.2.12)$$

$$E(Z_{n,k}) = 1 \cdot P((k-1, n-k)\text{-split}) = \frac{(n-1)!}{n!} = \frac{1}{n} \quad (10.2.13)$$

$$Y_n =^d = \sum_{k=1}^n Z_{n,k} \cdot 2 \max\{Y_{k-1}, Y_{n-k}\} \quad (10.2.14)$$

$$E(Y_n) = E\left(\sum_{k=1}^n Z_{n,k} \cdot 2 \max\{Y_{k-1}, Y_{n-k}\}\right) \quad (10.2.15)$$

$$E(Y_n) = 2 \sum_{k=1}^n E(Z_{n,k} \cdot \max\{Y_{k-1}, Y_{n-k}\}) \quad (10.2.16)$$

$$E(Y_n) = 2 \sum_{k=1}^n E(Z_{n,k}) \cdot E(\max\{Y_{k-1}, Y_{n-k}\}) \quad (10.2.17)$$

$$E(Y_n) = \frac{2}{n} \sum_{k=1}^n E(\max\{Y_{k-1}, Y_{n-k}\}) \quad (10.2.18)$$

$$\leq_{(\max xy \leq x+y)} \frac{2}{n} \sum_{k=1}^n E(Y_{k-1}) + E(Y_{n-k}) \quad (10.2.19)$$

$$E(H_n) = O(\log n), H_n = \log_2 Y_n \quad (10.2.20)$$

$$Y_{k-1} = 2^1 0, Y_{n-k} = 2^1 1 \quad (10.2.21)$$

$$\max 2^{10}, 2^{11} = 2^{11} \quad (10.2.22)$$

$$2^{10} + 2^{11} = 3 \cdot 2^{10} \quad (10.2.23)$$

$$= \frac{2}{n} \sum_{k=1}^n E(Y_{k-1}) + \sum_{k=1}^n E(Y_{n-k}) \quad (10.2.24)$$

$$= \frac{4}{n} \sum_{k=0}^{n-1} E(Y_k) \quad (10.2.25)$$

$$Y_n = E(Y_n) \quad (10.2.26)$$

$$y_n \leq \frac{4}{n} \sum_{k=0}^{n-1} y_k \quad (10.2.27)$$

$$ny_n \leq 4 \sum_{k=0}^{n-1} y_k \quad (10.2.28)$$

$$y_n = O(n^3) \quad (10.2.29)$$

Dowód indukcyjny. Założenie indukcyjne  $y_0 = y_1 = 0, \forall k < ny_k \leq cn^3$

$$\text{krok indukcyjny} \quad y_n \leq \frac{4}{n} \sum_{k=0}^{n-1} y_k \quad (10.2.30)$$

$$\leq_{\text{ind}} \frac{4}{n} \sum_{k=0}^{n-1} ck^3 = \quad (10.2.31)$$

$$= \frac{4c}{n} \sum_{k=0}^{n-1} k^3 = \quad (10.2.32)$$

$$= \frac{4c}{n} \cdot \frac{n^2(n-1)^2}{4} = \quad (10.2.33)$$

$$= cn(n-1)^2 \leq cn^3 \quad (10.2.34)$$

Zatem:

$$E(Y_n) = O(n^3) \quad (10.2.35)$$

□



Dokładny wynik pokazany przez Devroye 1986r.

$$E(H_n) \sim 2.9882 \log_2 n \quad (10.2.36)$$


## 11 Lecture XI

### 11.1 Red Black Trees

'78 Guibas, Sedgewick - Red Black (RB) Trees

- Własność 0 - Drzewa RB są drzewami BST - mają BST Property - po lewej stronie węzła występują wartości mniejsze, a po prawej większe
- Własność 1 - Każdy węzeł ma kolor czerwony albo czarny (to może być bit)
- Własność 2 - Korzeń oraz *liście* są czarne
- Własność 3 - Jeśli węzeł jest czerwony, to jego bezpośrednie dzieci są czarne
- Własność 4 -  $\forall X$  Każda prosta ścieżka od węzła  $X$  do liści ma tyle samo czarnych węzłów. ( $\text{black\_height}(x)$ , inaczej  $\text{bh}(x)$ ). Prosta ścieżka oznacza, że nie zawracamy, zawsze idziemy w dół.

### 11.2 Red Black Tree Example




Programując - ostatni liść - *nil* nie ma klucza, kolor jest czarny, a wskaźnik na ojca - to każdy węzeł. Liście drzewa RB to wszystkie *nil*-węzły.

**Przykład** Czarna wysokość  $\text{bh}(18) = 2$

**Lemat** Niech  $T$  będzie drzewem czerwono-czarnym o  $n$ -węzłach. Wtedy:

$$\text{wysokość}(T) \leq 2 \log_2(n + 1) \quad (11.2.1)$$

**Dowód** Czarni rodzice wchłaniają czerwone dzieci.



W drzewie binarnym liczba liści wynosi  $n + 1$   
(zawsze dokładamy 2 liście do każdego węzła - można to pokazać indukcyjnie)

**2-3-4-Tree.** Liczba liści nie zmienia się.

Mamy  $n + 1$  liści w drzewie czerwono-czarnym oraz w 2-3-4-drzewie (dowód - indukcyjnie)

- Niech  $h$  - wysokość drzewa czerwono-czarnego.
- Niech  $h'$  - wysokość odpowiadającego mu 2-3-4-drzewa.

Zauważmy, że  $h' = bh(\text{korzenia RB drzewa})$ . Ograniczmy liczbę liści za pomocą funkcji od tej wysokości

$$2^{h'} \leq \# \text{liści} \leq 4^{h'} \quad (11.2.2)$$

Węzły binarne o wysokości  $h'$  dają  $2^{h'}$  węzłów.

Węzły 2-3-4 o wysokości  $h'$  dają  $4^{h'}$  węzłów.

Naszych liści jest  $n + 1$ , zatem:

$$2^{h'} \leq n + 1 \quad (11.2.3)$$

$$h' \leq \log_2(n + 1) \quad (11.2.4)$$

Z konstrukcji wchłaniania wiemy, że  $h \leq 2h'$  (ponieważ każdy czarny węzeł może wchłaniać czerwone dzieci - z 2 razy wyższego drzewa). Zatem:

$$h \leq 2 \log_2(n + 1) \quad (11.2.5)$$

*W Javie 8 HashMapy były implementowane jako drzewa czerwono-czarne.*


Modyfikacja drzewa czerwono-czarnego obejmuje operacje różne od BST. Drzewo będzie wtedy zmieniać swoją strukturę aby zachować czarną wysokość - stąd również nazwa - self-balancing trees. Operacje niemodyfikujące drzewa czerwono-czarnego są tożsame z operacjami na drzewach BST.

### 11.3 Insert w Red Black Trees

RB\_Insert( $T, z$ )


1. Wstawiamy węzeł  $z$  do drzewa  $T$  tak jak w przypadku BST
2. Ustawiamy kolor węzła  $z$  na czerwony
3. Naprawiamy drzewo  $T$  - wywołujemy funkcję RB\_Fixup( $T, z$ )

Chcemy umieścić nowy węzeł (15) w drzewie czerwono-czarnym.




Operacje używane w procedurze Fixup

1. **recolor** -  $O(1)$  - zmiana koloru węzła - z czerwonego na czarny, z czarnego na czerwony
2. **rotate** -  $O(1)$  - rotacja węzła  $x$  w lewo lub w prawo.



Before Right Rotation




After Right Rotation

$$(\forall a \in \alpha b \in \beta c \in \gamma) (a \leq B \leq b \leq c \leq A) \quad (11.3.1)$$

RB\_Fixup(T,z)

**Case 1** -  $z$  jest czerwony, ojciec  $x$ , wujek  $w = z.p.p \rightsquigarrow$  inne dziecko,  $x = z.p$  jest czerwony oraz  $w$ -czerwony.




**Case 2** -  $z$  - czerwony,  $x$  - czarny,  $w$  - czarny, zachodzi zig-zag

**Case 3** -  $z$  - czerwony,  $x$  - czarny,  $w$  - czarny, bez zig-zag

*Podałem się z rysowaniem tego w tikz*

Ostatecznie



Wnioski

- Fixup -  $O(\log n)$
- Insert -  $O(\log n)$
- RB\_Insert -  $O(\log n)$

Inne drzewa od Red Black Trees to drzewa AVL (różnica stałych przy logarytmach), self-leaning left trees, skip list.

*Następny wykład - kolejna struktura implementująca interfejs set*

## 12 Lecture XI

### 12.1 Wzbogacanie struktur danych

TBD.

## 13 Lecture XII

### 13.1 Funkcje Hashujące

Universal Hash Property. Prawdopodobieństwo kolizji dla funkcji hashującej wynosi:

$$Pr(h_{a,b}(x) = h_{a,b}(y)) = \frac{1}{m} \quad (13.1.1)$$

$$f_{a,b}(x) = (ax + b) \mod p \quad (13.1.2)$$

$$g : \mathbb{Z}_l \rightarrow B.t.ż. \forall_{i \in B} |\{y \in \mathbb{Z}_p : g(y) = i\}| \leq \left\lceil \frac{p}{m} \right\rceil \quad (13.1.3)$$

Naturalny wybór  $g(y) = y \mod m$

$$h_{a,b}(x) = g(f_{a,b}(x)) \quad (13.1.4)$$

$$\mathcal{H} = \{h_{a,b} t.ż. a, b \in \mathbb{Z}_l, \quad a \neq 0\} \quad (13.1.5)$$

Lemat. Dla  $x, y \in A$ , t.ż.  $x \neq y$  zdefiniujemy:

$$\delta_H(x, y) = \delta_g(\mathbb{Z}_p, \mathbb{Z}_p) = \sum_{x, y \in \mathbb{Z}_p} \delta_g(x, y) \quad (13.1.6)$$

$$(13.1.7)$$

Funkcja  $\delta$  - zliczająca kolizje.

$$\delta_f = \begin{cases} 1 & \text{jeśli } f(x) = f(y) \\ 0 & \text{w p.p.} \end{cases} \quad (13.1.8)$$

Dowód. Niech  $r, s \in \mathbb{Z}_p$ ,  $r \neq s$ , para  $(r, s)$  odpowiada  $(f_{a,b}(x), f_{a,b}(y))$ , ponieważ  $a \neq 0$ ,  $x \neq y$ ,  $f_{a,b}(x) \neq f_{a,b}(y)$ . Możemy skorzystać ze znajomości algebry abstrakcyjnej:

$$ax + b = r \pmod{p} \quad ay + b = s \pmod{p} \quad (13.1.9)$$

Wiemy, że za pomocą rozszerzonego algorytmu Euklidesa możemy znaleźć unikalne  $a, b$ , takie że zadane kongruencje będą spełnione. Znajdźmy takie  $a, b$ , że nie zajdzie kolizja. Zatem:

$$(r, s) = (f_{a,b}(x), f_{a,b}(y)), \text{ to} \quad (13.1.10)$$

$$H(a, b)(x) = H(a, b)(y) \iff g(r) = g(s), \text{ stąd} \quad (13.1.11)$$

$$\delta_H(x, y) = \sum_{x, y \in \mathbb{Z}_p} \delta_g(x, y) \quad (13.1.12)$$

Lemat 2.  $\forall_{x, y \in A} \delta_H(x, y) \leq \frac{|H|}{|B|} = \frac{|H|}{m}$ . Dowód:

$$m_i = |\{y \in \mathbb{Z}_p : g(y) = i\}| < \left\lceil \frac{p}{m} \right\rceil \quad (13.1.13)$$

$$p, m \in \mathbb{Z} : \left\lceil \frac{p}{m} \right\rceil \leq \left( \frac{p-1}{m} \right) + 1 \quad (13.1.14)$$

Dla ustalonego  $r \in \mathbb{Z}_p$  mamy co najwyżej  $\frac{p-1}{m}$  's'-ów kolidujących. Możliwe  $r \in \mathbb{Z}_p$  jest  $p$  stąd mamy:

$$\delta_H(x, y) \leq \frac{p(p-1)}{m} = \frac{|H|}{m} = \frac{|H|}{|B|} \quad (13.1.15)$$

Wybierając jedną z tych funkcji (1 out of  $m$ )  $\leq \frac{1}{m}$

## 14 Lecture XIII

### 14.1 Programowanie Dynamiczne - Wstęp

Dzisiejszy wykład prowadzi p. Gębala. 05.05.2024

Dzielimy problem rekurencyjnie - ale nie rozwiązujemy go w ten sposób, ponieważ mniejsze podproblemy nie są rozłączne - tak jak w divide and conquer.

## 14.2 Przykład programowania dynamicznego - Ciąg Fibonacciego

$$F(n) = F(n-1) + F(n-2) \quad (14.2.1)$$

$$F(0) = 0 \quad (14.2.2)$$

$$F(1) = 1 \quad (14.2.3)$$

## 14.3 Najdłuższy rosnący podciąg

Input:  $a_1, \dots, a_n \in \mathbb{N}$

Output: największe  $k$ , takie że istnieje:

- ciąg indeksów  $1 \leq i_1 < i_2 < \dots < i_k \leq n$
- $a_{i_1} < a_{i_2} < \dots < a_{i_k}$

Patrzmy zakładając że znamy rozwiązanie dla  $N-1$ , co jeśli dodamy  $n$ -ty element.

1.  $L(i)$  - długość najdłuższego podciagu w zbiorze  $[1..i]$  z elementem końcowym w  $i$
2.  $L(i) = 1 + \max_{1 \leq j < i} \{L(j) : a_i > a_j\}$

Przykład

i	0	1	2	3	4	5
a <sub>i</sub>	2	3	1	5	4	3
L(i)	1	2	1	3	3	2

```
for i=1 to n do
    L(i) = 1 + max_{1 ≤ j < i} {L(j) : a_i > a_j}
```

```
return max_{1 ≤ i ≤ n} L(i)
```

Programowanie dynamiczne zakłada zapisywanie poprzednich kroków, tu:

$$L(i) \ (\forall i \leq n) \quad (14.3.1)$$

chcąc odzyskać ciąg powinniśmy zdefiniować:

$\text{prev}(i) = j$

1. Złożoność czasowa  $O(n^2)$  (for + max)
2. Złożoność pamięciowa  $O(n)$  (każdy  $L(i)$   $1 \leq i < n$ )

## 14.4 Problem wyznaczania reszty

Input:

- $c_1 < c_2 < \dots < c_n$  - zbiór nominałów  $\in \mathbb{N}$
- $R$  - reszta do wydania

Output:

- minimalne  $k$ , takie że  $k$ -monet wystarczy do wydania  $R$

Taktyka zachłanna nie działa dla np. 1,4,5,8:

- zachłanny - 5,1,1,1 - 4 monety
- optymalny - 4,4 - 2 monety

Rozwiążmy za pomocą programowania dynamicznego.

$$L(i) - \text{minimalna liczba monet do wydania reszty } i \quad (14.4.1)$$

$$L(i) = 1 + \min_{1 \leq j \leq n} \{L(i - c_j) : c_j \leq i\} \quad (14.4.2)$$

$$L(0) = 0 \quad (14.4.3)$$

c\_1, c\_2, c\_3 = 1, 4, 5

Per i sprawdzamy każdą resztę 1, 4, 5

```
i      0 1 2 3 4 5 6 7 8
L(i)  0 1 2 3 1 1 2 3 2
```

Złożność  $O(n \cdot R)$ , liczymy minimum w pętli for. Prev backtrace

```
0 1 1 1 4 5 5 1 4
----->
          ----->
```

i-4 = 4 jmp to 4

Co jeśli mamy  $\{2, 4, 5\} \in C$ , wtedy:

```
i 0 1
L(i) 0 +infty
```

Nie da się wydać reszty 1.

Fakt 1. Jeżeli zbiór monet zawiera nominał 1, to rozwiązanie istnieje dla każdego  $R \in \mathbb{N}$ . Decyzja kiedy występuje największa liczba, której nie potrafimy wydać jest problemem NP-trudnym.

Zachłanny algorytm działa dla zbioru monet, które są wielokrotnościami siebie, a w szczególności gdy

$$\forall_{i,j} i < j \rightarrow 2c_1 \leq c_j \quad (14.4.4)$$

Długość danych  $n \cdot \log c_n + \log_2 R = m$  - bitowe wejście, jeśli  $n \log c_n \leq \log R$ , wtedy:

$$O(nR) = O(n \cdot 2^{O(m)}) \quad (14.4.5)$$

$R$  - liczba, a nie wielkość zapisu danych.

## 14.5 Rozkład liczby pierwszej

Input: p - liczba, długość  $\log_2(p)$  (bitowa)

Output: Czynniki pierwsze rozkładu p

$$O(\sqrt{p}) \rightarrow O(\sqrt{(\sqrt{2^{\log_2(p)}})}) \quad (14.5.1)$$

## 14.6 Knapsack - Problem Plecakowy

Input:

- $n$  par (waga, wartość)  $(w_i, v_i)$
- ograniczenie górne na pojemność plecaka  $W$ .

Output:

- $I \subseteq \{1, \dots, n\}$  tż:
  1.  $\sum_{i \in I} w_i \leq W$
  2.  $\sum_{i \in I} v_i$  jest największa

Istotnym założeniem, które musimy podjąć jest:

$$\forall_i w_i \leq W \quad (14.6.1)$$

Ponieważ musimy ignorować pojedyncze przedmioty, które są większe od pojemności plecaka.

Niech  $V(n)$  - maksymalna wartość na  $n$  przedmiotach.

$$V(n, w) = \max\{v(n-1, w), V(n-1, w-w_n) + v_n\} \quad (14.6.2)$$

Wyjaśnienie wyboru parametrów funkcji max:

- $v(n-1, w)$  - nie bierzemy  $n$ -tego przedmiotu
- $V(n-1, w-w_n) + v_n$  - bierzemy  $n$ -ty przedmiot, ale musimy zmniejszyć pojemność plecaka o wagę  $w_n$ .

Podajmy kroki początkowe w rekurencji:

$$V(0, *) = 0 \quad (14.6.3)$$

$$V(n, W) = \max\{V(i-1, w), V(i-1, w-w_i) + v_i\} \quad (14.6.4)$$

$$V(0, w) = V(j, 0) = 0 \quad (\forall j \in \{0, \dots, n\} i w \in 0, \dots, w) \quad (14.6.5)$$

```
for i <- 1 to n do
  for w <- 0 to W do
    if w_i > w then V(i,w) = V(i-1,w)
    else V(i,w) <- max(V(i-1,w), V(i-1,w-w_i) + v_i)
```

$$O(n \cdot W) \quad (14.6.6)$$

$$O(n \cdot 2^{O(m)}) \quad (14.6.7)$$

Zobaczmy, że jeśli  $w \leftarrow 2^{20} \cdot w$  (dodajemy 20 zer binarnie)  $2^{20}$  większy czas, to jest algorytm wykładniczy. Jeśli  $W = O(n)$  to algorytm jest  $n^2$ .

- Insertion sort - dynamicznie dodajemy element  $n+1$  do posortowanej listy długości  $n$



## 14.7 Optymalne Mnożenie Macierzy

Input: Macierze  $A_1, \dots, A_n$ ,  $A_i : m_{i-1} \times m_i$

Przykład  $(10,2) * (2,10) * (10,3)$

-  $(10*2*10) + (10*10*3) = 500$  mnożeń

-  $(10*2*3) + (2*10*3) = 120$  mnożeń

$$c(i, j) = \text{optymalny koszt przemnożenia } A_i \times \dots \times A_j \quad (14.7.1)$$

$$c(i, i) = 0 \quad (14.7.2)$$

$$c(i, j) = \min_{i \leq k < j} (c(i, k) + c(k+1, j) + m_{i-1} \cdot m_k \cdot m_j) \quad (14.7.3)$$

$$i < j \text{ ostatnie mnożenie } k \quad (14.7.4)$$

$\frac{n^2}{2}$  wartość  $\cdot n = O(n^3)$


Wzór rekurencyjny, ale liczymy od dołu. Należy udowodnić poprawność rozwiązania.

## 15 Lecture XIV

### 15.1 Programowanie Dynamiczne - Kontynuacja

### 15.2 Grafy Skierowane

$G = (V, E)$ ,  $|V| = n$ ,  $|E| = m$ ,  $V$  - wierzchołki,  $E$  - krawędzie.



### 15.3 Najkrótsze ścieżki w DAG'ach - Directed Acyclic Graph

Grafy skierowane acykliczne nie posiadają cykli. Jesteśmy w stanie posortować grafy skierowane acykliczne w kolejności topologicznej.

Graf S1. Może być więcej niż jedno źródło/ujęcie.

Chcemy policzyć najkrótsze ścieżki od  $S$  do każdego innego wierzchołka.

Założmy że chcemy dojść do  $A$ .

$$L(A) = \min\{L(S) + w(s, A), L(C) + w(C, A)\} \quad (15.3.1)$$

Input:  $G=(V,E)$

$S \in V$  = source vertice

for each  $v \in V$

$L(v) = \infty$  // jeżeli nie ma trasy to dystans będzie ustalony na nieskończoność

$L(S) = 0$

for each  $v \in V \setminus \{s\}$  // w porządku topologicznym

$L(v) = \min_{(u,v) \in E} \{L(u) + w(u,v)\}$

Nie chcemy w programowaniu dynamicznym rekurencji, ponieważ nasze podproblemy będą się powtarzać. To jest zasadnicza różnica między programowaniem rekurencyjnym (np. divide and conquer), a dynamicznym. Będziemy zapamiętywać rozwiązania.

Przed pętlą mamy  $\Theta(|V|)$ , a w pętli  $\Theta(\text{indeg}(V))$ , suma wszystkich krawędzi przychodzących, czyli mamy  $\Theta(|E|)$ . Złożoność zadanego algorytmu to  $\Theta(n + m)$ , w najgorszym przypadku - mając najwięcej  $m = n^2$  krawędzi, mamy  $\Theta(n + n^2)$ .

Jak tworzyć algorytmy dynamiczne:

1. Zdefiniować podproblem.
2. Zdefiniować kolejność na podproblemach.
3. Zdefiniować relację.

## 15.4 Edit Distance Problem

Input:  $w_1, w_2$  - słowa  $|w_1| = n, |w_2| = m$ ,  $\Sigma$  - alfabet Output:  $\text{EditDistance}(w_1, w_2)$  - minimalna liczba operacji dodania, usunięcia, podmiany znaków w słowach  $w_1 \rightsquigarrow w_2$

Przykład - chcemy przejść ze SNOWY do SUNNY

S\_NOWY

SUNN\_Y

010110 -> w sumie 3 operacje.

- Rozpychamy U, zmieniamy O na N, Usuwamy W. Mamy 3 operacje.

\_SNOW\_Y

SUN\_\_NY

1101110 -> w sumie 5 operacji.

- Wstawiamy S, podmieniamy S na U, Usuwamy O, Usuwamy W, Wstawiamy N

$E(i, j)$  - edit distance  $w_1[1 \dots i], w_2[1 \dots j]$

Z jakich podproblemów dochodzimy do  $E(i, j)$ ?

- dodanie litery do  $w_2$  -  $E(i, j - 1) + 1$
- usunięcie litery z  $w_2$  -  $E(i - 1, j) + 1$  Dopasowujemy do  $w_2$  bez jednej litery.
- podmiana listery z  $w_2$  -  $E(i - 1, j - 1) + 1$  Podmiana litery in place
- bez zmian  $w_2$  -  $E(i - 1, j - 1)$

$\text{diff}(w_1[i], w_2[i])$  - zwraca 0 lub 1 w zależności czy jest różnica w znakach.

```
for i=0 to m
  E(i,0) = i
for j=0...n E(0,j) = j
for i=1 to m
  for j=1 to n
    E(i,j) = min(E(i-1,j)+1, E(i,j-1)+1, E(i-1,j-1) + diff(w[i],w[j]))
```

Analiza złożoności obliczeniowej - pętla1 -  $\Theta(m)$ , pętla2 -  $\Theta(n)$ , pętla ostatnia  $\Theta(n \cdot m)$ .  
 Złożoność pamięciowa  $\Theta(m \cdot n)$ , lub jeśli nie zależy nam na krokach to  $\Theta(\min\{m, n\})$   
 (pamiętamy każdorazowo ostatnie dwa wiersze).

```

      S N O W Y
    0 1 2 3 4 5
S 1 0 1 2 3 4
U 2 1 1 2 3 4
N 3 2 1 2 3 4
N 4 3 2 2 3 4
Y 5 4 3 3 3 3

```

Therefore  
`EditDistance("SNOWY", "SUNNY") = 3`

Co na ogół jest podproblemami - np. prefix ciągu, podciąg zwarty (consecutive).

## 16 Lecture XV


### 16.1 Kopiec binarny (Binary Heap)

- Pełne drzewo binarne przetrzymywane w tablicy.

```

I : 1 2 3 4 5 6 7 8 9 10
A : [16, 14, 10, 8, 7, 9, 3, 2, 4, 1]

```



```

left(i) = 2i (LSH)
right(i) = 2i + 1 (LSH + 1)
parent(i) = i // 2 (RSH)
size(A) = rozmiar listy

```

### 16.2 Własność kopca (maksymalnego)

$$\forall_i A[\text{parent}(i)] > A[i] \quad (16.2.1)$$

- Wysokość węzła to długość najdłuższej prostej ścieżki od tego węzła do liścia.

```

HEAPIFY(A, i)
  l = left(i)
  r = right(i)

```

```


# find maximum element from i, l, r
if (l <= size(A) AND A[l] > A[i])
    largest = l
else
    largest = i
if (r <= size(A) AND A[r] > A[largest])
    largest = r
# end find

# swap if so
if largest != i
    swap(A[i], A[largest])
HEAPIFY(A, largest)


```

Przykład


1st step



2nd step



3rd step



Złożoność obliczeniowa

i

```

      /      \
(2/3 el.) (1/3 el.)
..         ..
..         ..
.. (schodek)

```

```

L = 2^h - 1
P = 2^{h-1} - 1 - liczba elementów

```

$$T(n) = O(1) + T(2/3n) \quad (16.2.2)$$

Z Master Theorem mamy:

$$a = 1 \quad (16.2.3)$$

$$b = \frac{3}{2} \quad (16.2.4)$$

$$d = 0 \quad (16.2.5)$$

$$(16.2.6)$$

Zatem  $\log_{\frac{3}{2}} 1 = d = 0$ , więc mamy  $n^d \log n = \log n$

$$T(n) = O(\log n) \quad (16.2.7)$$

$\text{floor}(\text{size}(A)/2)$  to indeks pierwszego nie-liścia. Pierwszym nie-liściem jest parent ostatniego liścia.

```

BuildHeap(A)
  size(A) = length(A)
  for i = floor(size(A)/2) to 1 // i--
    HEAPIFY(A,i)

```

A: 4, 1, 3, 2, 16, 9, 10, 14, 8, 7

```

      4
     / \
    1   3
   / \ / \
  2  16 9 10
 / \ /
14 8 7


```

```


...
intermediate-steps
...

```

AT i = 2



AT i = 1



RESULT: 16, 14, 10, 14, 8, 7, 9, 3, 2, 4, 1

Złożność obliczeniowa dla BuildHeap.

$$|A| = n, \frac{n}{2} \text{razy Heapify} \quad (16.2.8)$$

$$O(n \log n) \quad (16.2.9)$$

**Fact. Kopiec.** W  $n$ -elementowym kopcu binarnym mamy co najwyżej  $\lceil \frac{n}{2^{h+1}} \rceil$  węzłów o wysokości  $h$ . Dowód.

Indukcja po  $h$ . Dla  $h = 0$  (liście) mamy co najwyżej  $\frac{n}{2^{0+1}}$  liści to jest prawda.

Założenie indukcyjne  $\forall_{k < h} \# \text{węzłów o wysokości } k \leq \lceil \frac{n}{2^{k+1}} \rceil$

Krok indukcyjny. Węzły o wysokości  $k - 1$  zał. ind  $\leq \lceil \frac{n}{2^{k-1+1}} \rceil$ . Zatem węzłów o wysokości  $h$  mamy co najwyżej  $\frac{1}{2} \lceil \frac{n}{2^k} \rceil \leq \lceil \frac{n}{2^{k+1}} \rceil$

Złożoność obliczeniową BuildHeap można również wyrazić jako

$$O \left( \sum_{h=1}^{\log n} \# \text{węzłów o wysokości } h \cdot h \right) \leq \quad (16.2.10)$$

$$\leq O \left( \sum_{h=0}^{\log n} \frac{n}{2^{h+1}} \cdot h \right) = \quad (16.2.11)$$

$$= O \left( n \sum_{h=0}^{\log n} \frac{h}{2^{h-1}} \right) = \quad (16.2.12)$$

$$= O \left( \frac{n}{(1 - \frac{1}{2})^2} \right) = \quad (16.2.13)$$

$$= O(n) \quad (16.2.14)$$

Istnieje HeapSort.

### 16.3 Kolejka Priorytetowa (PQ)

- Insert(Q,x)
- Maximum(Q) : return Q[1], O(1)
- ExtractMax(Q) - zwraca element o najw. priorytecie, usuń z Q
- Increase/Decrease Key(Q,x,y) - zmieniamy z x na y
- Delete(Q,i)
- Union(Q1,Q2) : BuildHeap([Q1,Q2]), O(|Q1|+|Q2|)

```
Delete(Q, i)
    Q[i] = Q[size(Q)]
    size(Q)--
    if (Q[i] < Q[parent(i)])
        Heapify(Q, i)
    else
        while (i > 1 && Q[parent(i)] < Q[i])
            swap(Q[i], Q[parent(i)])
            i = parent(i) : O(log n)
```

```
Insert(Q, key)
    size(Q)++
    i = size(Q)
    while(i > 1 && Q[parent(i)] < key)
        Q[i] = Q[parent(i)]
        i = parent(i)
    Q[i] = key : O(log n)
```

```
ExtractMax(Q)
    if Q.size < 1 return null
    else
        max=Q[1]
        Q[1] = Q[size(Q)]
        size(Q)--
        Heapify(Q,1)
    return max
```